

Méthodes de classification non supervisée (Cluster analysis)

Dyhia BENHADDAD & Manuella IKOUTOU SOUAMY


Université Le Havre Normandie
UFR Sciences et Techniques
Master 1 Mathématiques et Applications
Encadré par M^{me} Sylviane WEY

3 juin 2026

Sommaire

- 1 Introduction
- 2 Présentation du jeu de données *Decathlon*
- 3 Objectifs de la classification
- 4 Analyse en Composantes Principales
- 5 Classification Ascendante Hiérarchique
- 6 K-means
- 7 Density-Based Spatial Clustering of Applications with Noise
- 8 Qualité de représentation
- 9 Comparaison des méthodes
- 10 Conclusion
- 11 Bibliographie

Introduction



Notre étude porte sur l'apprentissage **non supervisé**.
Trois méthodes : CAH, K-means et DBSCAN sont appliquées au jeu de données
Decathlon.

? Problématique

Comment les méthodes de classification non supervisée permettent-elles de **révéler des structures significatives** dans un jeu de données, et selon quels critères peut-on **évaluer objectivement** la qualité des partitions obtenues ?

Présentation du jeu de données : *Decathlon*

- **41 athlètes** : JO (28) et Decastar (13)
- **13 variables** : 10 disciplines + points, classement et compétition
- Sens des variables :
 - Courses : temps élevé = **mauvaise** performance
 - Sauts/Lancers : distance élevée = **bonne** performance

Variables étudiées

Courses : 100 m, 400 m, 110 m haies, 1500 m

Sauts : Longueur, Hauteur, Perche

Lancers : Poids, Disque, Javelot

Pré-traitement

Suppression : points, classement et compétition

Standardisation :

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{\sigma_j}$$

Corrélations importantes

$r = +0,58$ (100 m et 110 m haies)

$r = +0,62$ (Poids et Disque)

$r = -0,60$ (Longueur et 100 m)

Objectifs de la classification

μ_k : poids de C_k w_i : poids de l'individu i g_k : centre de gravité de C_k g : centre de gravité global

Homogénéité

Individus d'un même cluster
présentant une forte similarité

⇒ Minimiser l'inertie intra-classe :

$$W = \sum_{k=1}^K \sum_{i \in C_k} w_i d^2(x_i, g_k)$$

Séparation

Clusters
aussi distincts que possible

⇒ Maximiser l'inertie inter-classe :

$$B = \sum_{k=1}^K \mu_k d^2(g_k, g)$$

Théorème de Huygens

$T = W + B$ (inertie totale, indépendante de la partition)

Minimiser $W \iff$ Maximiser B

Analyse en Composantes Principales

Pourquoi l'ACP ?

Dix variables corrélées sur *Decathlon*

- **Espace de grande dimension** :
difficile de visualiser et d'interpréter
- **Redondance** : des variables corrélées apportent la même information

On utilise uniquement l'**Analyse en composante principale** normée.

Objectif

Transformer p variables corrélées en $q \ll p$ **composantes principales** non corrélées

Formalisation

Matrice de corrélation Σ :

$$\Sigma = \frac{1}{n} X^T X$$

Diagonaliser Σ en résolvant la décomposition spectrale :

$$\Sigma u_k = \lambda_k u_k \quad \text{avec} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

La k -ième composante principale :


$$F_k = X u_k$$

ACP : choix du nombre de composantes

Variance expliquée et choix de q

- **Variance totale** : $\sum_k \lambda_k$
- **Variance expliquée** : $\tau(q) = \frac{\sum_{k=1}^q \lambda_k}{\sum_{k=1}^p \lambda_k}$
- **Règle de Kaiser** : retenir $\lambda_k > 1$
- **Scree plot** : coude de la courbe
- **Seuil de variance** : $\tau(q) \geq 70\%$

CP	λ_k	% cumulé	Kaiser
CP1	3,27	32,72 %	✓
CP2	1,74	50,09 %	✓
CP3	1,40	64,14 %	✓
CP4	1,06	74,71 %	✓
CP5	0,68	81,56 %	×





⇒ **4 composantes retenues** (74,7 % de variance)

⇒ Plan de représentation (**CP1, CP2**) = 50,1 %

Support commun de visualisation pour les trois méthodes de clustering.

ACP : cercle des corrélations et projection



CP1 (32,7 %) : performance globale

+ Longueur, Poids, Disque, Hauteur

– 100 m, 110 m haies, 400 m, 1500 m

CP2 (17,4 %) : lancer/ endurance

+ Disque, Poids, 400, 1500m – Longueur

Classification Ascendante Hiérarchique

Principe

Partir de n singletons et fusionner itérativement les deux classes les plus proches jusqu'à une classe unique (dendrogramme).

Algorithme

- 1 Chaque individu forme sa propre classe
- 2 Calculer la matrice des distances
- 3 Fusionner (C_a, C_b) minimisant $D(C_a, C_b)$
- 4 Mettre à jour les distances
- 5 Répéter jusqu'à une seule classe


Critères d'agrégation

Critère	Formule
Lien simple → Effet de chaîne	$\min_{i \in C_a, j \in C_b} d(i, j)$
Lien complet → Classes compactes	$\max_{i \in C_a, j \in C_b} d(i, j)$
Lien moyen → Compromis, plus robuste	$\frac{1}{n_{C_a} \cdot n_{C_b}} \sum_{i \in C_a} \sum_{j \in C_b} d(i, j)$
Centroïde → Inversions possibles	$d(g_{C_a}, g_{C_b})$
Ward → Minimise la perte d'inertie ⇒ classes compactes et équilibrées	$\frac{\mu_a \mu_b}{\mu_a + \mu_b} d^2(g_a, g_b)$

CAH : dendrogramme (critère de Ward)

$$D_W(C_a, C_b) = \frac{\mu_a \mu_b}{\mu_a + \mu_b} d^2(g_a, g_b)$$


Dendrogramme de Decathlon



CAH : choix du nombre de classes

Saut d'inertie

Repérer le plus grand saut dans les hauteurs de fusion du dendrogramme → K optimal.




Indice de silhouette

Pour chaque individu i :

$$s_{sil}(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, 1]$$

$a(i)$: distance moy. aux individus du même cluster


$b(i)$: distance moy. au cluster voisin le plus proche



Saut d'inertie → $K = 4$; Silhouette → $K = 6$; Les deux critères ne convergent pas vers le même K .

⇒ $K = 4$ retenues (interprétabilité + effectifs suffisants)

CAH : visualisation des 4 classes



CAH : description des 4 classes

Classe	Variable	v.test	Moy. classe	Moy. globale
Classe 1 ($n = 3$)	Longueur	3,468	7,87	7,26
	Disque	3,107	50,16	44,325
	400m	-2.333	48.120	49.616
Classe 2 ($n = 19$)	100m	-2.265	10,897	10.998
	1500m	-2.975	273,186	279,024
Classe 3 ($n = 11$)	1500m	3,899	290,763	279,024
	Longueur	-2.038	7,093	7,26
Classe 4 ($n = 8$)	100m	4,053	11,336	10,998
	Hauteur	-2,412	1,908	1,976
	Poids	-3,134	13,657	14,477

Description des classes

- **Classe 1** : Sebrle, Clay et Karpov.
→ Dominance sur toutes les disciplines.
- **Classe 2** : athlètes relativement rapides et endurants.
- **Classe 3** : athlètes moins performants en endurance et en saut.
- **Classe 4** : niveau le plus faible
→ Majoritairement composée d'athlètes du Decastar.

K-means

Principe

- Partitionner un jeu de données en K classes, en minimisant W .
- K est fixé **a priori**.

Algorithme

- 1 Fixer K , initialiser les centres de gravité des K classes
- 2 Affecter chaque individu au centre le plus proche :

$$k^* = \arg \min_{k=1, \dots, K} d(x_i, g_k)$$

- 3 Calculer le centre de gravité de la nouvelle classe
- 4 Répéter jusqu'à stabilité des affectations

Illustration

Étape 1 : initialisation



Étape 2 : affectation



Étape 3 : nouveaux centres




K-means : choix du nombre de classes

Méthode du coude


Tracer W en fonction de K et retenir le K à partir duquel la décroissance ralentit.

Méthode du coude (K-means)




Indice de silhouette

Méthode des silhouettes (K-means)



Coude $\rightarrow K = 4$; Silhouette $\rightarrow K = 2$; Les deux critères ne convergent pas vers le même K .
 $\Rightarrow K = 4$ retenues

K-means : visualisation des 4 classes



K-means : description des 4 classes

Classe	Variable	v.test	Moy. classe	Moy. globale
Classe 1 ($n = 13$)	100m	4.460	11.267	10.998
	400m	4.186	50.723	49.616
	Longueur	-3.532	7.004	7.260
Classe 2 ($n = 3$)	Longueur	3.469	7.870	7.260
	Disque	3.108	50.160	44.326
	400m	-2.334	48.120	49.616
	100m	-2.746	10.597	10.998
Classe 3 ($n = 13$)	Perche	4.453	5.046	4.762
Classe 4 ($n = 12$)	1500m	-2.893	270.825	279.025
	Perche	-3.716	4.512	4.762

Description des classes

- **Classe 1** : athlètes moins performants en vitesse et saut
→ Similaire à la classe 4 de la CAH ;
- **Classe 2** : Sebrle, Clay, Karpov
→ Identique à la classe 1 de la CAH.
- **Classe 3** : athlètes performants au saut à la perche
→ Isolation d'une spécialité.
- **Classe 4** : profil endurant
→ Perche en dessous de la moyenne..

Density-Based Spatial Clustering of Applications with Noise

Principe

Méthode basée sur la **densité** : les clusters sont des zones denses séparées par des zones de faible densité.

- K non fixé a priori
- Détecte les formes arbitraires
- Identifie les **points aberrants**

Deux paramètres clés


ε : rayon du voisinage d'un point

$$V_\varepsilon(y) = \{y' \in \Omega \mid d(y, y') < \varepsilon\}$$

MinPts : nombre minimal de points dans $V_\varepsilon(y)$ pour former une région dense

$$|V_\varepsilon(y)| \geq \text{MinPts}$$

Typologie des points



Type	Condition
Core point	$ V_\varepsilon(y) \geq \text{MinPts}$
Border point	dans V_ε d'un core, pas core lui-même
Bruit	ni core, ni border

DBSCAN : algorithme et choix des paramètres

Algorithme

- 1 Fixer ε et MinPts
- 2 Choisir un point y non visité
- 3 Marquer y comme visité ; calculer $V_\varepsilon(y)$
- 4 Si $|V_\varepsilon(y)| \geq \text{MinPts}$:
 - Créer un nouveau cluster
 - Étendre le cluster aux voisins accessibles par densité
- 5 Sinon : marquer y comme **bruit**
- 6 Répéter jusqu'à ce que tous les points soient visités

Choix des paramètres

Choix de MinPts

Règle générale : $\text{MinPts} = 2 \times p$

En faible dimension : $\text{MinPts} = 3, 4$ ou 5


Choix de ε : k -NN distance plot

1. Calculer pour chaque point sa distance au k -ième plus proche voisin
2. Trier par ordre croissant et tracer la courbe
3. Choisir ε au **coude** de la courbe

DBSCAN : choix des paramètres sur Decathlon


Espace 10D : inadapté

Solution : espace (CP1, CP2)



4-NN distance plot (10D)

Pas de coude net $\Rightarrow$ distances homogènes
Pour tout ε testé : 1 seul cluster
 $\Rightarrow$ DBSCAN **inadapté** en 10D



3-NN distance plot (CP1, CP2)

Coude net à $\varepsilon \approx 1,5$
Seul $\varepsilon = 1,5 \Rightarrow$ 3 clusters + 3 points bruit
 $\Rightarrow$ **Retenus** : $\varepsilon = 1,5$, MinPts = 3
sur (CP1, CP2)

DBSCAN : description des 3 classes

Classe	Variable	v.test	Moy. classe	Moy. globale
Classe 1 ($n = 3$)	Longueur	3,469	7,870	7,260
	Disque	3,108	50,160	44,326
	400m	-2,334	48,120	49,616
	100m	-2,746	10,597	10,998
Classe 2 ($n = 32$)	Disque	-2,042	43,754	44,326
	Poids	-2,465	14,309	14,477
Classe 3 ($n = 3$)	400m	1,961	50,873	49,616

Description des classes

Classe 1 ($n=3$) : Sebrle, Clay, Karpov
→ Identique aux classes 1 et 2 de la CAH et de K-means ;
→ Dominance sur toutes les disciplines.

Classe 3 ($n=3$) : Parkhomenko, Korkizoglou, YURKOV
→ 400 m supérieure à la moyenne (légère faiblesse en endurance).


Classe 2 ($n=32$) : zone centrale dense
→ Distribution continue ;
→ Disque et Poids inférieurs à la moyenne.

Bruit ($n=3$) : Warners, Drews, Casarsa
→ Positions isolées dans (CP1,CP2) ;
→ Profils atypiques, pas aberrants.

Qualité de représentation des méthodes

CAH


Qualité de représentation avec Indice de Silhouette ($k = 4$)



Classe	Effec.	Sil.
1	3	0,327
2	19	0,147
3	11	−0,005
4	8	0,207
Total	41	0,131

K-means


Qualité de représentation avec Indice de Silhouette ($k = 4$)



Classe	Effec.	Sil.
1	13	0,060
2	3	0,303
3	13	0,133
4	12	0,195
Total	41	0,141

DBSCAN

DBSCAN : silhouette par cluster



Classe	Effec.	Sil.
1	3	0,785
2	32	0,189
3	3	0,885
Total	38	0,291

Comparaison des méthodes

	CAH	K-means	DBSCAN
Nb. classes	4	4	3 + bruit
Effectifs	3/19/11/8	13/3/13/12	3/32/3
Silhouette	0,131	0,141	0,291
η^2 CP1	0,734	0,805	0,431
η^2 CP2	0,470	0,176	0,239
K fixé a priori	×	✓	×
Élites identifiées	✓	✓	✓
Profil perche isolé	×	✓	×
Profil endurant isolé	×	✓	×
Points aberrants	×	×	✓
Detection forme arbitraires	×	×	✓

Conclusion

- **CAH** : Représentation hiérarchique, K a posteriori, capte CP1 et CP2
- **K-means** : Partition équilibrée, profils masqués détectés (perche, endurance)
- **DBSCAN** : Identifie les profils atypiques, nécessite une réduction de dimension

Il n'existe pas de méthode universelle optimale. Le choix de l'algorithme dépend de la **nature des données**, de la **présence de bruit** et des **objectifs de l'analyse**.


Bibliographie

-  Brian S. Everitt, Sabine Landau, Morven Leese, Daniel Stahl, *Cluster Analysis*, 5th Edition, Wiley, 2011.
-  Jean-Pierre Nakache et Josiane Confais, *Méthodes de classification*, Éditions Technip, 2004.
-  Sylviane Wey, *Classification Ascendante Hiérarchique (Chapitre 5)*, Polycopié de cours de Master 1, Université Le Havre Normandie, 2025.
-  Jean-Marie Monnez, *Méthodes de classification non supervisée*, Cours d'analyse des données et apprentissage, Université de Lorraine, 2021.
-  Marie Chavent, *Classification de données quantitatives*, Cours, Université de Bordeaux, 2013.
-  Valérie Monbet, *Clustering et Classification Ascendante Hiérarchique (CAH) - Introduction*, Cours, Université de Rennes 1.

Merci pour votre attention !

Lien simple


$$\min_{i \in C_a, j \in C_b} d(i, j)$$



Individu
Agglomerative Coefficient = 0.36

Lien complet


$$\max_{i \in C_a, j \in C_b} d(i, j)$$



Individu
Agglomerative Coefficient = 0.7

Lien moyen


$$\frac{1}{n_{C_a} \cdot n_{C_b}} \sum_{i \in C_a} \sum_{j \in C_b} d(i, j)$$



Individu
Agglomerative Coefficient = 0.55

Centre de gravité

$$d(g_{C_a}, g_{C_b})$$



Individu
hclust ("", "centroid")