

UNIVERSITÉ LE HAVRE NORMANDIE



UFR Sciences et Techniques
Master 1 Mathématiques et Applications
Année universitaire : 2025-2026

Travail personnel encadré (TPE)

Méthodes de classification non supervisée (Cluster analysis)

Réalisé par :

Dyhia BENHADDAD.

Manuella IKOUTOU SOUAMY.

Encadré par :

M^{me} Sylviane WEY.

5 juin 2026

Abstract

Identifying hidden structures in data is one of the main challenges in statistics, especially when no prior information about the groups is available. Unsupervised classification addresses this challenge by automatically grouping similar individuals without any prior knowledge of the classes to form.

Several methods exist to answer this problem, however two important questions arise : which one to choose, and how to know if a grouping is good when no reference answer exists ? This work is organised around these questions.

Three different algorithms are studied and compared : Hierarchical Agglomerative Clustering, which progressively builds a hierarchy of groups represented by a dendrogram ; K-means, which finds the best partition by minimising the internal dispersion of the classes and DBSCAN, which identifies clusters as dense regions of the space without fixing their number in advance.

Principal Component Analysis is used beforehand to reduce the dimension of the data, by providing a common representation space in which these methods are applied and whose results are assessed using internal validation criteria such as the silhouette index and the elbow method.

These methods are applied to a real dataset, where their results reveal a significant but moderate structure. It follows from this analysis that no method stands as a universal solution, but rather that their complementarity allows for a more complete and in-depth reading of the data.

Table des matières

Abstract	1
Introduction	4
1 Fondamentaux théoriques	5
1.1 Notion de ressemblance et choix de la distance	5
1.2 Préparation des données	6
1.3 Espace de classification et Inertie	7
1.4 Objectifs de la classification	8
1.5 Analyse en composantes principales	9
1.5.1 Principe et objectif	9
1.5.2 Formalisation mathématique	10
1.5.3 Représentations graphiques	10
2 Etudes des méthodes	12
2.1 Classification Ascendante Hiérarchique (CAH)	12
2.1.1 Principe	12
2.1.2 Algorithme	12
2.1.3 Critères d'agrégation	12
2.1.4 Avantages de la CAH	17
2.1.5 Limites de la CAH	17
2.2 Méthode K-moyennes (K-means)	17
2.2.1 Principe	17
2.2.2 Algorithme	17
2.2.3 Avantages des K-means	18
2.2.4 Limites des K-means	18
2.3 DBSCAN (<i>Density-Based Spatial Clustering of Applications with Noise</i>)	18
2.3.1 Principe	18
2.3.2 Paramètres clés et typologie des points	18
2.3.3 Algorithme	19
2.3.4 Choix des paramètres ε et MinPts	20
2.3.5 Avantages de DBSCAN	20
2.3.6 Limites de DBSCAN	20
3 Critères de validation	21
3.1 Méthode du coude	21
3.2 Indice de silhouette	21
3.3 Indice de Davies-Bouldin	22
4 Mise en application sur une base de données	23
4.1 Présentation et traitement du jeu de données	23
4.2 Analyse en Composantes Principales	24
4.2.1 Choix du nombre de composantes	24
4.2.2 Interprétations des axes	25
4.2.3 Projection des individus et qualité de représentation	26
4.3 Classification Ascendante Hiérarchique	28
4.3.1 Choix du nombre de classes	28
4.3.2 Description et interprétations des classes	29
4.3.3 Qualité de représentation	31
4.4 Classification par K-means	31
4.4.1 Choix du nombre de classes	31
4.4.2 Description et interprétation des classes	32
4.4.3 Qualité de représentation	34
4.5 Classification par DBSCAN	34
4.5.1 Choix des paramètres ε et MinPts	34
4.5.2 Interprétations des classes	35
4.5.3 Qualité de représentation	37

4.6	Lien entre ACP et les classifications	38
4.6.1	ACP et CAH	38
4.6.2	ACP et K-means	38
4.6.3	ACP et DBSCAN	39
Conclusion		40
A Démonstration du théorème de Huygens		41
B Scripts R		42
B.1	Pré-traitement commun	42
B.2	Script ACP	43
B.3	Script CAH	44
B.4	Script K-means	47
B.5	Script DBSCAN	48
B.6	Script Critères d'aggrégation : <i>USArrests</i>	50
Bibliographie		54

Table des figures

1	CAH : Critère du lien simple (single linkage)	13
2	CAH : Critère du lien complet (complete linkage)	14
3	CAH : Critère du lien moyen (average linkage)	15
4	CAH : Méthode du centre de gravité (centroïd linkage)	15
5	CAH : Méthode de Ward	16
6	ACP : Scree plot	25
7	ACP : Scree plot avec variance expliquée	25
8	ACP : cercle des corrélations	25
9	ACP : Contribution des variables à (CP1,CP2)	26
10	ACP : projection des individus	26
11	ACP : Qualité de représentation ($\cos^2$)	27
12	ACP : Contribution des individus à (CP1,CP2)	27
13	ACP : Répartition des athlètes par compétition	28
14	CAH : dendrogramme	28
15	CAH : Saut d'inertie	29
16	CAH : Méthode des silhouettes	29
17	CAH : Clusters dans (CP1,CP2)	29
18	CAH : Qualité de représentation	31
19	K-means : Méthode du coude	32
20	K-means : Méthode des silhouettes	32
21	K-means : Clusters dans (CP1,CP2)	32
22	K-means : Qualité de représentation	34
23	DBSCAN : 4-NN distance plot sur les données standardisées	35
24	DBSCAN : 3-NN distance plot sur (CP1,CP2)	35
25	DBSCAN : Clusters dans (CP1,CP2) ($\varepsilon = 1.5$ et $MinPts = 3$)	36
26	DBSCAN : Qualité de représentation	37

Introduction

L'apprentissage statistique vise à modéliser et comprendre les phénomènes sous-jacents aux données, en reposant sur des bases mathématiques solides.

Cet apprentissage se divise en deux grandes familles selon la nature de l'information : apprentissage supervisé et non supervisé.

L'apprentissage supervisé s'appuie sur une variable connue pour construire un modèle à partir d'exemples annotés. Autrement dit, l'apprentissage supervisé apprend à classer un nouvel individu parmi un ensemble de classes prédéfinies.

En revanche, l'apprentissage non supervisé opère en l'absence de toute donnée étiquetée ; il cherche à trouver une structure cachée directement à partir des caractéristiques observées. Cela signifie que le nombre et la définition des groupes sont inconnus *a priori*.

C'est dans cette seconde famille qu'appartiennent les méthodes de classification non supervisée, également appelées clustering, segmentation ou analyse typologique.

L'objectif du clustering est de partitionner un ensemble d'individus en sous-groupes disjoints, appelés classes ou clusters, de telle sorte que les individus appartenant à un même groupe partagent des caractéristiques communes (homogénéité) et que les groupes soient les plus distincts possible les uns des autres (séparation).

La diversité des structures que peuvent présenter les données conduit à une grande variété d'algorithmes de clustering, chacun reposant sur une hypothèse différente.

Les méthodes par partitionnement, telles que K-means, optimisent un critère global de dispersion. Les méthodes hiérarchiques, comme la Classification Ascendante Hiérarchique, construisent une hiérarchie de regroupements. Les méthodes fondées sur la densité, dont DBSCAN, identifient les clusters comme des zones denses de l'espace séparées par des régions de faible densité.

Cette diversité soulève deux difficultés de l'apprentissage non supervisé.

La première concerne le choix de la méthode la plus adaptée à un jeu de données. La seconde porte sur l'évaluation de la qualité d'une partition et à la détermination du nombre de classes.

En effet, en l'absence de groupes de référence connus, aucune comparaison directe avec une solution attendue n'est possible.

Ainsi, notre étude cherche à répondre à la problématique suivante :

comment les différentes méthodes de classification non supervisée permettent-elles de révéler des structures significatives au sein d'un jeu de données, et selon quels critères peut-on objectivement évaluer et comparer la qualité des partitions obtenues ?

Pour répondre à cette problématique, ce rapport s'organise en quatre parties :

- La première partie pose les fondements mathématiques indispensables à la compréhension des méthodes ;
- La deuxième partie étudie trois algorithmes des grandes familles de clustering : la Classification Ascendante Hiérarchique (CAH), la méthode des K-means et l'algorithme DBSCAN ;
- La troisième partie est consacrée aux critères de validation des partitions permettant de sélectionner le nombre optimal de classes et d'évaluer la qualité des partitions obtenues ;
- La quatrième partie applique les concepts et méthodes présentés dans les parties précédentes sur un jeu de données réel Decathlon. L'analyse se conclut par l'étude du lien entre l'ACP et chacune des méthodes de classification.

Toutes les analyses sont effectuées avec le logiciel *R*.

1 Fondamentaux théoriques

Pour faire apparaître la structure cachée d'un jeu de données, les méthodes de classification non supervisées s'appuient sur des concepts mathématiques stricts qu'il convient de définir. Cette partie présente ces fondements, allant des mesures de ressemblance jusqu'à l'Analyse en Composantes Principales.

1.1 Notion de ressemblance et choix de la distance

L'une des missions du clustering est de regrouper des individus en fonction de leurs similarités. Pour que ce processus puisse être automatisé, il est nécessaire de traduire le concept intuitif de "ressemblance" en une mesure mathématique concrète. Deux approches sont possibles :

Soit $\Omega = \{1, \dots, i, \dots, n\}$ un ensemble de n individus décrits par p variables.

Définition 1 (Mesure de similarité). : Une mesure de similarité est une fonction pour laquelle une valeur élevée traduit une forte proximité entre deux individus. Soit $s : \Omega \times \Omega \rightarrow \mathbb{R}^+$, on a :

$$s(i, j) \geq 0 \quad ; \quad s(i, j) = s(j, i) \quad \text{et} \quad s(i, i) = s(j, j) = s_{\max} \geq s(i, j) \quad (\forall i, j \in \Omega) \quad (1)$$

où $s_{\max}$ est la plus grande similarité possible.

Définition 2 (Mesure de dissimilarité). : Une mesure de dissimilarité est une fonction pour laquelle une valeur élevée traduit un éloignement important entre deux individus. Soit $d : \Omega \times \Omega \rightarrow \mathbb{R}^+$, on a :

$$d(i, j) \geq 0 \quad ; \quad d(i, j) = d(j, i) \quad \text{et} \quad d(i, i) = 0 \quad (\forall i, j \in \Omega) \quad (2)$$

Dans la pratique, la plupart des méthodes de classification reposent sur une mesure de dissimilarité qui vérifie également l'inégalité triangulaire :

$$\forall i, j, k \in \Omega, d(i, j) \leq d(i, k) + d(k, j)$$

Plus la distance séparant deux observations est faible, plus ces observations sont considérées comme similaires.

Cependant, la méthode de calcul de cet écart n'est pas unique. Le choix de la distance dépend strictement de la nature des variables étudiées au sein du jeu de données. Il convient de faire une distinction majeure entre le traitement des variables quantitatives et celui des variables qualitatives.

a) Variables quantitatives

Lorsque les variables observées sont quantitatives, qu'elles soient discrètes ou continues. Plusieurs métriques peuvent être utilisées pour mesurer la dissimilarité entre deux individus. On peut notamment citer :

Soient deux observations x_i, x_j et p variables quantitatives.

- **La distance de Manhattan** : correspond à la somme des différences absolues entre les coordonnées. Elle est moins sensible aux valeurs extrêmes car elle ne repose pas sur l'élévation au carré des écarts.

$$d(i, j) = \sum_{k=1}^p |x_{ik} - x_{jk}|$$

- **La distance de Tchebychev** : correspond au maximum des différences absolues observées sur l'ensemble des variables. Cette métrique est particulièrement adaptée lorsque l'on souhaite que la dissimilarité soit dominée par la plus grande différence observée.

$$d(i, j) = \max_{k=1, \dots, p} |x_{ik} - x_{jk}|$$

- **La distance euclidienne** : représente géométriquement la longueur du segment reliant les deux points considérés.

$$d(i, j) = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} \quad (3)$$

Bien que ces distances puissent être utilisées dans différents contextes, la distance euclidienne est particulièrement adaptée lorsque les variables quantitatives ont des variances équivalentes. Dans ce cadre, elle constitue la métrique de référence en classification.

Toutefois, l'usage direct de la distance euclidienne pose un problème : si une variable présente une variance nettement plus élevée que les autres, les écarts observés sur cette variable domineront la distance totale.

Il est alors courant d'utiliser une version normalisée de la distance euclidienne. Celle-ci consiste à diviser chaque variable par son écart-type avant le calcul de la distance, ce qui revient à travailler sur des variables centrées et réduites.

b) Variables qualitatives

Lorsque les variables sont qualitatives, les observations ne prennent plus des valeurs numériques mesurables mais des modalités appartenant à des catégories (nominales ou ordinales). Dans ce contexte, les distances basées sur des écarts numériques telles que la distance euclidienne, ne sont pas adaptées.

La mesure la plus intuitive est alors **la distance de Hamming**. Celle-ci repose sur un principe simple : compter le nombre de variables pour lesquelles deux individus présentent des modalités différentes.

Soient deux observations x, y et p variables qualitatives.

$$d_H(x, y) = \sum_{i=1}^p \delta(x_i, y_i) \quad (4)$$

où

$$\delta(x_i, y_i) = \begin{cases} 0 & \text{si } x_i = y_i, \\ 1 & \text{si } x_i \neq y_i. \end{cases}$$

Dans le cas de variables **nominales** (variables sans ordre naturel) cette distance est parfaitement adaptée. En effet, seule l'égalité ou la différence entre catégories est pertinente et le simple décompte des désaccords constitue une mesure cohérente de dissimilarité.

En revanche, lorsque les variables sont **ordinales** (variables avec ordre naturel) la distance de Hamming ne prend pas en compte cette structure ordinale et considère toute différence comme équivalente, indépendamment de l'écart réelle entre les catégories. Ainsi, deux modalités consécutives sont traitées de la même manière que deux modalités situées aux extrêmes de l'échelle.

Pour remédier à ce problème, deux approches sont possibles :

- Traiter les variables ordinales comme des variables nominales en acceptant la perte d'information liée à l'ordre.
- Attribuer un codage numérique respectant la hiérarchie des modalités, afin de pouvoir utiliser une distance adaptée aux variables quantitatives.

1.2 Préparation des données

Avant d'appliquer un algorithme de classification, une étape de préparation des données est souvent indispensable. Celle-ci peut inclure le traitement des valeurs manquantes, l'encodage des variables ou encore la transformation de certaines variables.

Toutefois, les méthodes de clustering s'appuient fortement sur une mesure de distance sensible aux unités de mesure et aux échelles des variables.

Dans ce cas, il est nécessaire de ramener toutes les variables à une échelle comparable grâce aux opérations de **centrage** et de **réduction** (ou standardisation).

Soit X_{ij} la valeur de la variable j observée pour l'individu i , avec $i \in \{1, \dots, n\}$ et $j \in \{1, \dots, p\}$.

On définit :

- La **moyenne empirique** de la variable j :

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}$$

— L'écart-type empirique de la variable j :

$$\sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2}$$

a) Centrage

Le centrage consiste à soustraire à chaque observation la moyenne de la variable correspondante :

$$X_{ij}^c = X_{ij} - \bar{X}_j \quad (5)$$

Cette opération permet de recentrer la moyenne de chaque variable autour de zéro, sans modifier la dispersion des valeurs. De plus, elle est utile lorsque l'on souhaite supprimer un effet de position et comparer les variables sur une base commune.

b) Réduction

La réduction consiste à diviser la variable centrée par son écart-type :

$$Z_{ij} = \frac{(X_{ij} - \bar{X}_j)}{\sigma_j} \quad (6)$$

Cette transformation conduit à une variable de moyenne nulle et de variance égale à 1. Elle permet d'éliminer les effets liés aux différences de dispersion entre les variables, assurant ainsi une contribution équilibrée de chacune d'elles dans le calcul des distances.

Ainsi, le centrage et la réduction permettent de garantir une contribution équilibrée des variables dans le calcul des distances. Une fois les données préparées, les individus peuvent être représentés dans un espace métrique où la notion de distance structure directement la formation des groupes.

1.3 Espace de classification et Inertie

La classification repose sur la présentation des individus dans un espace métrique adapté. Les notions de partition, de hiérarchie et d'inertie permettent alors de formaliser mathématiquement la structure des groupes obtenus.

a) Partition

Une partition P en K classes de Ω est un ensemble $(C_1, \dots, C_k, \dots, C_K)$ de classes non vides, d'intersections vides deux à deux et dont la réunion forme Ω .

Autrement dit, dans le cadre de la classification, on va diviser notre jeu de données en plusieurs sous-groupes (les clusters) en respectant trois règles absolues :

- Chaque individu doit appartenir à un et un seul groupe (les groupes sont disjoints) :
 $\forall k, k' \in \{1, \dots, K\} \quad C_k \cap C_{k'} = \emptyset$;
- Aucun groupe ne doit être vide : $\forall k \in \{1, \dots, K\}, \quad C_k \neq \emptyset$;
- L'union des groupes est Ω : $\cup_{k=1, \dots, K} C_k = \Omega$.

b) Hiérarchie

Une hiérarchie H de Ω est un ensemble de classes non vides qui vérifient :

- $\Omega \in H$
- $\forall i \in \Omega, \{i\} \in H$ (la hiérarchie contient tous les singletons)
- $\forall A, B \in H, A \cap B \in \{A, B, \emptyset\}$ (deux classes de la hiérarchie sont soit disjointes soit contenues l'une dans l'autre)

c) Hiérarchie indicée

Une hiérarchie indicée est un couple (H, h) où H est une hiérarchie et h est une fonction de H dans $\mathbb{R}^+$ telle que :

- $\forall A \in H, h(A) = 0 \iff A$ est un singleton.
- $\forall A, B \in H, A \neq B, A \subset B \Rightarrow h(A) \leq h(B)$.

d) Inertie

L'inertie est un concept physique appliqué aux statistiques, c'est l'équivalent de la variance, mais pour des données multidimensionnelles.

Elle permet de mesurer la dispersion globale d'un nuage de points (les observations) autour de son centre de gravité (le point moyen de toutes nos données).

On associe à chaque individu $i \in \Omega$ un poids $w_i > 0$ vérifiant :

$$\sum_{i=1}^n w_i = 1.$$

On considère le nuage des n points de $\Omega = \{1, \dots, i, \dots, n\}$ pondérés par w_i et décrit par un vecteur $x_i \in \mathbb{R}^p$. Pour une classe $C_k \subset \Omega$, on définit :

- $\mu_k = \sum_{i \in C_k} w_i$: poids de C_k
- $g_k = \frac{1}{\mu_k} \sum_{i \in C_k} w_i x_i$: centre de gravité de C_k
- d : distance euclidienne.

Inertie par rapport à un point $a \in \mathbb{R}^p$:

$$I_a = \sum_{i=1}^n w_i d^2(x_i, a) \quad (7)$$

Inertie totale :

$$T = \sum_{i=1}^n w_i d^2(x_i, g) \quad \text{avec } g \text{ le centre de gravité} \quad (8)$$

Cette inertie totale est indépendante de la partition et nous permet de quantifier à quel point nos sous-groupes répondent aux critères **d'homogénéité et de séparation**.

1.4 Objectifs de la classification

Pour qu'une partition soit considérée comme pertinente d'un point de vue statistique, elle doit satisfaire simultanément deux critères fondamentaux : l'homogénéité et la séparation.

a) Homogénéité

L'homogénéité consiste à s'assurer que les individus regroupés au sein d'un même cluster se ressemblent fortement. En d'autres termes, les observations situées à l'intérieur d'un même groupe doivent présenter une forte similarité entre elles.

D'un point de vue mathématique, cet objectif se traduit par la nécessité de minimiser la dispersion des points autour du centre de leur propre groupe.

Cette dispersion est appelée **l'inertie intra-classe** et a pour formule :

$$W = \sum_{k=1}^K I(C_k) \quad \text{et} \quad I(C_k) = \sum_{i \in C_k} w_i d^2(x_i, g_k) \quad (9)$$

Plus cette inertie est faible, plus le cluster est considéré comme compact et les données qui le composent homogènes.

b) Séparation

À l'inverse de l'homogénéité, la séparation vise à assurer que les classes formées soient les plus distinctes possible les unes des autres. Les groupes doivent être bien séparés dans l'espace des données.

Mathématiquement, cela implique de maximiser la dispersion des centres de gravité des classes par rapport au centre de gravité global du nuage de points.

On parle d'**inertie inter-classe** tel que :

$$B = \sum_{k=1}^K \mu_k d^2(g_k, g) \quad (10)$$

Il est crucial de souligner que ces deux objectifs sont intrinsèquement liés par le **théorème de Huygens** :

$$T = W + B \quad (11)$$

(Voir démonstration du théorème en annexe A).

Par conséquent, chercher à maximiser l'homogénéité des classes (en minimisant l'inertie intra-classe) revient à maximiser leur séparation (en maximisant l'inertie inter-classe). C'est ce mécanisme de balancier mathématique qui est au cœur des algorithmes de classification.

1.5 Analyse en composantes principales

Les sections 1.2 et 1.3 montrent que les méthodes de classification opèrent dans un espace $\mathbb{R}^p$, où p désigne le nombre de variables décrivant les individus. Néanmoins, lorsque p est élevé, deux difficultés apparaissent :

- Le problème de dimension : dans un espace de grande dimension, les distances entre individus tendent à se concentrer, rendant les notions de proximité et d'éloignement moins visibles ;
- La redondance des variables : de nombreuses variables peuvent être corrélées entre elles, sans apporter d'information supplémentaire à l'analyse.

L'Analyse en Composantes Principales (ACP) répond à ces deux problèmes et constitue ainsi une étape de préparation avancée des données, complémentaire du centrage-réduction.

1.5.1 Principe et objectif

L'ACP est une méthode statistique, introduite par Pearson (1901) et formalisée par Hotelling (1933). Son objectif est de transformer un ensemble de p variables d'origine (potentiellement corrélées) en un ensemble de q nouvelles variables non corrélées, appelées composantes principales, ordonnées par variance décroissante.

Ces composantes principales sont des combinaisons linéaires des variables d'origine. Elles sont construites telles que :

- la première composante explique la part de variance maximale des données ;
- chaque composante suivante est orthogonale à toutes les précédentes et explique la part de variance résiduelle maximale.

En conservant uniquement les q premières composantes ($q \ll p$), on projette les données dans un sous-espace de dimension réduite qui concentre l'essentiel de l'information. Les coordonnées des individus dans ce sous-espace constituent les nouvelles variables sur lesquelles les algorithmes de clustering seront appliqués. Il existe deux types d'Analyse en Composante Principale.

- ACP non-normée sur une matrice de données centrées ;
- ACP normée sur une matrice de données centrées-réduites.

Dans la suite de notre projet, nous utiliserons uniquement l'Analyse en Composante Principale normée.

1.5.2 Formalisation mathématique

a) Centrage et Réduction

L'ACP est très sensible à l'échelle des variables. On travaille donc quasi systématiquement sur les données centrées et réduites.

b) Matrice de variance-covariance

Soit X la matrice de données centrée-réduite, de dimensions $n \times p$, avec n individus et p variables.

On cherche à construire des axes $u_k \in \mathbb{R}^p$, (vecteurs unitaires $\|u_k\| = 1$) tels que la projection des individus sur ces axes maximise la variance expliquée.

La matrice de variance-covariance se confond avec la matrice de corrélation :

$$\Sigma = \frac{1}{n} X^T X \quad (12)$$

où X^T désigne la matrice transposée.

Ses termes diagonaux valent 1 et ses termes hors-diagonale mesurent les corrélations entre variables. C'est cette matrice que l'ACP va diagonaliser pour en extraire les directions de variance maximale.

c) Décomposition spectrale

Le théorème spectral garantit que Σ est symétrique semi-définie positive et admet donc une décomposition en valeurs propres réelles et positives :

$$\Sigma u_k = \lambda_k u_k \quad \text{avec} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0 \quad (13)$$

Les vecteurs propres u_k (eigenvectors) définissent les composantes principales, et les valeurs propres λ_k (eigenvalues) mesurent la variance expliquée par chaque composante. La k -ième composante principale est donc la projection :

$$F_k = X u_k$$

d) Variance expliquée et choix de q

La variance totale du nuage de points est égale à la trace de Σ , soit $\sum_k \lambda_k$. La part de variance expliquée par les q premières composantes est :

$$\tau(q) = \frac{\sum_{k=1}^q \lambda_k}{\sum_{k=1}^p \lambda_k} \quad (14)$$

Le choix du nombre q de composantes à retenir repose sur des critères complémentaires :

- Seuil de variance expliquée cumulée : on retient les q premières composantes dès que $\tau(q)$ dépasse un seuil fixé, généralement 70% à 80%.
- Règle de Kaiser : on ne conserve que les composantes dont la valeur propre λ_k est supérieure à 1, ce qui correspond, sur données centrées-réduites, aux axes qui expliquent plus de variance qu'une variable d'origine.
- Scree plot : on représente les valeurs propres par ordre décroissant et on retient les composantes situées avant le coude de la courbe, par analogie avec la méthode du coude de la section 3.1.

1.5.3 Représentations graphiques

L'ACP donne deux représentations complémentaires qui facilitent l'interprétation des résultats.

a) Cercle des corrélations

Le cercle des corrélations représente les variables d'origine dans le plan des deux composantes principales qui expliquent au mieux l'inertie du nuage de points. Chaque variable est un vecteur dont la longueur indique sa qualité de représentation sur le plan et l'angle entre deux vecteurs reflète leur corrélation ; deux variables fortement corrélées apparaissent proches l'une de l'autre.

b) Nuage des individus

Le plan factoriel (F_1, F_2) représente les individus par leurs coordonnées dans le nouvel espace réduit. C'est sur ce plan que les groupes formés par le clustering seront visualisés offrant une représentation intuitive des structures détectées.

L'ACP constitue une étape de préparation des données qui s'inscrit dans la continuité des sections 1.2 et 1.3. En construisant un espace de représentation réduit et non redondant, elle conditionne la qualité des résultats de clustering.

Son apport est double : améliore la robustesse des algorithmes en réduisant la dimensionnalité et le bruit, et fournit un cadre de visualisation indispensable à l'interprétation des groupes formés.

Les notions de distance, d'inertie, de standardisation, de hiérarchie et de partition définies dans cette partie seront mobilisés tout au long du rapport et une application complète de l'Analyse en Composantes Principales au jeu de données *Decathlon* sera conduite en section 4.

2 Etudes des méthodes

Les méthodes de classification non supervisée, se basant sur les mesures de similarité et les concepts d'inertie définis précédemment, peuvent être regroupées en plusieurs grandes familles :

- les méthodes **hiérarchiques**, qui construisent une structure de classe emboîtée de classifications successives ;
- les méthodes de **partitionnement**, où le nombre de classes est fixé au départ ;
- les méthodes **basées sur la densité**, qui identifient les groupes comme des régions de forte densité séparées par des zones de faible densité.

Nous étudions ici trois algorithmes représentatifs de ces approches : la classification hiérarchique ascendante (CAH), l'algorithme des K-means et la méthode DBSCAN.

2.1 Classification Ascendante Hiérarchique (CAH)

2.1.1 Principe

La classification ascendante hiérarchique (CAH) est une méthode hiérarchique, permettant de regrouper les observations d'un jeu de données de façon itérative, en fonction de leur proximité (distance entre les n individus).

Elle part de la partition triviale, chaque individu forme une classe (n classes), à chaque étape on cherche à regrouper les deux classes les plus similaires de la partition précédente jusqu'à obtenir un seul groupe contenant tous les individus.

Ces regroupements successifs sont représentés sous la forme d'un arbre de classification appelé **dendrogramme**.

Définition 3 (Dendrogramme). *Un dendrogramme est la représentation graphique d'une hiérarchie indicée. La fonction h mesure la hauteur des classes dans ce dendrogramme.*

Elle est généralement définie par :

$$h(A \cup B) = D(A, B) \quad (15)$$

où $h(A \cup B)$ représente la hauteur de la classe $A \cup B$ dans le dendrogramme de H .

2.1.2 Algorithme

1. Initialisation :
On part de la partition la plus fine, c'est la partition des singletons $P_n = (C_1 \dots, C_n)$ avec $C_k = \{k\}$.
2. Calculer la matrice de distances entre classes.
3. Étape agrégative :
On agrège les deux classes C_a et C_b de la partition P_K en K classes obtenue à l'étape précédente, qui minimisent une mesure d'agrégation $D(C_a, C_b)$.
Une nouvelle partition P_{K-1} en $K - 1$ classes est ainsi obtenue.
4. Répéter l'étape (3) jusqu'à obtenir la partition en une classe $P_1 = (\Omega)$.

2.1.3 Critères d'agrégation

La dissimilarité entre deux classes C_a et C_b est définie par un critère d'agrégation qui détermine à chaque itération les classes à regrouper. Le choix de ce critère est important car il influence la structure de la hiérarchie obtenue et donc la partition finale.

Pour illustrer cette influence, chaque critère présenté ci-dessous est appliqué au jeu de données *USArrests*, disponible sur le logiciel *R*. Ce jeu liste quatre indicateurs de criminalité (variables) pour les 50 états des États-Unis : taux de meurtre (*Murder*), d'agression (*Assault*), de viol (*Rape*) et proportion de population urbaine (*UrbanPop*).

Le tableau suivant montre les six premières observations du jeu de données, obtenues à l'aide de la fonction *head()* de *R* :

TABLE 1 – Les six premières observations du jeu de données *USArrests*

État	Murder	Assault	UrbanPop	Rape
Alabama	13.2	236	58	21.2
Alaska	10.0	263	48	44.5
Arizona	8.1	294	80	31.0
Arkansas	8.8	190	50	19.5
California	9.0	276	91	40.6
Colorado	7.9	204	78	38.7

Le résumé statistique des variables, est présenté dans le tableau suivant :

TABLE 2 – Résumé statistique des variables de *USArrests*

	Murder	Assault	UrbanPop	Rape
Min.	0.800	45.0	32.00	7.30
1st Qu.	4.075	109.0	54.50	15.07
Median	7.250	159.0	66.00	20.10
Mean	7.788	170.8	65.54	21.23
3rd Qu.	11.250	249.0	77.75	26.18
Max.	17.400	337.0	91.00	46.00

Les variables étant d'échelles différentes (le taux d'agression varie de 45 à 337, le taux de meurtre est compris entre 0,8 et 17,4), une standardisation est faite (voir section 1.2) pour assurer une contribution équitable de chaque variable au calcul des distances euclidiennes.


Pour chaque critère, le dendrogramme obtenu est découpé en 3 classes à l'aide de la fonction `cutree()` de *R*, cela revient à tracer une ligne horizontale dans l'arbre pour récupérer les partitions formées. Le choix de $k = 3$ est justifié par la structure des données, les 50 États se répartissant en trois niveaux de criminalité distincts : faible, modéré et élevé.

a) Lien simple (single linkage)

L'agrégation entre deux classes C_a et C_b correspond au minimum des distances entre un élément du groupe C_a et un élément du groupe C_b .

$$D(C_a, C_b) = \min_{i \in C_a, j \in C_b} d(i, j) \quad (16)$$

FIGURE 1 – CAH : Critère du lien simple (single linkage)



Le lien simple produit une partition déséquilibrée : 48 États se retrouvent dans un seul grand groupe, tandis que l'Alaska et la Florida sont tous deux isolés. Ce résultat est caractéristique de l'**effet de chaîne** : les États se regroupent progressivement via des individus les plus proches, formant une longue chaîne. Cette partition ne révèle alors aucune structure réelle.


La hauteur maximale de fusion, qui mesure la distance (dissimilarité) à laquelle les deux groupes finaux se rejoignent est très faible (≈ 2), ce qui indique que les derniers groupes sont peu éloignés donc mal séparés.

b) Lien complet (complete linkage)

L'agrégation entre deux classes C_a et C_b correspond au maximum des distances entre un élément du groupe C_a et un élément du groupe C_b .

$$D(C_a, C_b) = \max_{i \in C_a, j \in C_b} d(i, j) \quad (17)$$

FIGURE 2 – CAH : Critère du lien complet (complete linkage)



Le lien complet produit trois partitions plus équilibrées et interprétables que le lien simple.

- Le groupe 1 (vert) regroupe 8 États à forte criminalité : Alaska, Alabama, Louisiana, Georgia, Tennessee, North Carolina, Mississippi, South Carolina
- Le groupe 2 (rouge) regroupe 11 États présentant un niveau de criminalité modéré à élevé : Colorado, California, Nevada, Florida, Texas, Illinois, New York, Arizona, Michigan, Maryland, New Mexico
- Le groupe 3 (bleu) regroupe 31 États à faible criminalité : South Dakota, Vermont, Maine, Idaho, Montana, Nebraska, Connecticut, Wisconsin...

La hauteur maximale de fusion élevée (≈ 6) de cette partition indique une grande distance entre les classes. Les arbres sont structurellement différents du lien simple.


c) Lien moyen (average linkage)

On calcule toutes les distances possibles entre les observations appartenant au groupe C_a et celles appartenant au groupe C_b et on détermine la moyenne de ces distances. Les deux groupes dont la distance moyenne est la plus petite sont ceux qui seront regroupés pour l'itération en cours.

$$D(C_a, C_b) = \frac{1}{n_{C_a} \cdot n_{C_b}} \sum_{i \in C_a} \sum_{j \in C_b} d(i, j) \quad (18)$$

avec n_{C_a} et n_{C_b} sont respectivement le nombre d'objets dans chacun des deux classes C_a et C_b .

FIGURE 3 – CAH : Critère du lien moyen (average linkage)



Le lien moyen produit une partition de 19, 1 et 30 États.

- Le groupe 1 (vert) correspond aux 19 États avec un taux de criminalité élevé : Georgia, Alabama, Louisiana, North Carolina, Mississippi, California, Nevada, Florida...
- Le groupe 2 (rouge) représente 1 État : Alaska, isolé en raison de son taux de viol très élevé.
- Groupe 3 (bleu) regroupe 30 États possédant un taux de criminalité faible : North Dakota, Maine, Iowa, Vermont, Delaware, Connecticut, Wisconsin, Idaho...

La hauteur maximale de fusion (≈ 3) est intermédiaire entre le lien simple et le lien complet.


d) Méthode du centre de gravité (centroïd linkage)

La distance entre deux groupes C_a et C_b est définie par la distance entre leurs centres de gravité :

$$D = d(g_{C_a}, g_{C_b}). \quad (19)$$

avec g_{C_a} et g_{C_b} sont respectivement les centres de gravité de C_a et C_b .

FIGURE 4 – CAH : Méthode du centre de gravité (centroïd linkage)



Le centroïd linkage produit une partition similaire au lien simple.

- Groupe 1 (vert) : 48 États
- Groupe 2 (rouge) : Alaska
- Groupe 3 (bleu) : Vermont

Le centroïde génère des inversions dans le dendrogramme, confirmé par les sorties R qui détectent 7 occurrences (voir table 3). Ces inversions se traduisent par des branches qui descendent au lieu de monter, révélant une instabilité numérique du critère.

TABLE 3 – Inversions observées dans le dendrogramme

Étape	Hauteur précédente	Hauteur après inversion
3 → 4	0.4288	0.4179
11 → 12	0.6195	0.5660
22 → 23	0.7922	0.6962
26 → 27	0.8446	0.7751
29 → 30	0.9041	0.7741
31 → 32	0.9084	0.7863
42 → 43	1.2180	1.2042

e) Critère de Ward

Le critère de Ward est le plus utilisé en pratique. Il s'applique, si on est muni d'un espace euclidien. Il consiste à agréger à chaque itération les deux classes, tel que l'augmentation de l'inertie intra-classe soit minimale ce qui revient à maximiser l'inertie inter-classe :


$$D_W(C_a, C_b) = \frac{\mu_a \mu_b}{\mu_a + \mu_b} d^2(g_a, g_b) \quad (20)$$

où μ_a et μ_b désignent les poids respectifs des classes C_a et C_b et g_a, g_b leurs centres de gravité.

Pour le critère de Ward, la dissimilarité entre la nouvelle classe $C_{ab} = C_a \cup C_b$ et une classe quelconque C_q peut être mise à jour sans recalculer toutes les distances, grâce à la formule de **Lance et Williams** :

$$D_W(C_{ab}, C_q) = \frac{\mu_a + \mu_q}{\mu_a + \mu_b + \mu_q} D_W(C_a, C_q) + \frac{\mu_b + \mu_q}{\mu_a + \mu_b + \mu_q} D_W(C_b, C_q) - \frac{\mu_q}{\mu_a + \mu_b + \mu_q} D_W(C_a, C_b) \quad (21)$$

FIGURE 5 – CAH : Méthode de Ward



Avec trois groupes équilibrés (19, 12 et 19 États) correspondant à des niveaux de criminalité distincts, la méthode de Ward produit la partition la plus équilibrée et interprétable.

- Le groupe 1 (vert) regroupe les 19 États à criminalité modérée : Virginia, Wyoming, Arkansas, Kentucky, Delaware, Massachusetts, New Jersey, Connecticut, Missouri, Oregon, Indiana, Kansas, Ohio, Hawaii...
- Le groupe 2 (rouge) représente les 12 États ayant un taux de criminalité très faible : South Dakota, West Virginia, North Dakota, Vermont, Idaho, Montana, Nebraska, Minnesota, Wisconsin, Maine, Iowa, New Hampshire
- Le groupe 3 (bleu) regroupe 19 États à forte criminalité : Alabama, Louisiana, Georgia, Tennessee, North Carolina, Mississippi, Texas, Illinois, Florida, Arizona, Alaska, California, Nevada...

La hauteur maximale de fusion très élevée (≈ 12) indique une séparation nette entre les trois partitions.

Parmi les cinq critères étudiés, seul Ward produit trois classes homogènes, bien séparées et cohérentes avec les niveaux de criminalité des États.

En minimisant à chaque étape l'augmentation de l'inertie intra-classe, Ward offre le meilleur compromis entre équilibre, stabilité et interprétabilité, faisant de lui le critère le plus utilisé en classification et celui retenu dans la partie application de ce rapport.

2.1.4 Avantages de la CAH

- Il n'est pas nécessaire de choisir le nombre de classes à l'avance, celui-ci peut être déterminé après l'analyse grâce au dendrogramme.
- Le dendrogramme permet de visualiser la structure des données et de comprendre comment les groupes se forment.
- La méthode peut être utilisée pour des données qualitatives et quantitatives.

2.1.5 Limites de la CAH

- Pour un grand jeu de données, l'algorithme de la CAH devient coûteux en temps de calcul.
- Il y a une difficulté d'interprétation du dendrogramme lorsque le jeu de données est très grand.
- Une fois que des groupes sont fusionnés, ils ne peuvent plus être séparés.

2.2 Méthode K-moyennes (K-means)

2.2.1 Principe

Contrairement à la CAH, l'algorithme des K-means, introduite par Macqueen en 1967, est une méthode de partitionnement où le nombre de classes K doit être fixé à l'avance.

Son objectif est de partitionner un ensemble de données en K classes de façon à minimiser l'inertie intra-classe et maximiser l'inertie inter-classe.

L'algorithme débute par une partition initiale des données ou par le choix de K centres initiaux (centroïdes). Chaque observation est ensuite affectée à la classe dont le centre est le plus proche au sens d'une distance, généralement euclidienne.

L'algorithme procède alors de manière itérative en répétant les deux étapes suivantes :

- Chaque individu est affecté à la classe dont le centre est le plus proche ;
- Les centroïdes sont recalculés comme les centres de gravité des nouvelles classes obtenues.

Le processus est répété jusqu'à convergence, c'est-à-dire jusqu'à ce que les affectations des individus ou les positions des centroïdes ne changent plus, ou jusqu'à atteindre un nombre maximal d'itérations fixé à l'avance.

2.2.2 Algorithme

Soit $x_i \in \mathbb{R}^p$ avec $i \in \{1, \dots, n\}$

1. Initialisation :

On fixe à priori le nombre de classes K .

On part d'une partition initiale $P_K = (C_1, \dots, C_K)$ et on calcule les centres de gravité associés $g_1, \dots, g_K$.

2. Étape d'affectation :
 Initialiser $\text{test} \leftarrow 0$.
 Pour tout i allant de 1 à n faire :
 - Déterminer la classe k^* :

$$k^* = \arg \min_{k=1, \dots, K} d(x_i, g_k)$$
 - Soit ℓ la classe actuelle de x_i .
 - Si $k^* \neq \ell$ alors :
 - $\text{test} \leftarrow 1$
 - $C_{k^*} \leftarrow C_{k^*} \cup \{x_i\}$
 - $C_\ell \leftarrow C_\ell \setminus \{x_i\}$
3. Étape de mise à jour :
 Pour tout $k = 1, \dots, K$, calculer le centre de gravité g_k de la nouvelle classe C_k .
4. Arrêt :
 Si $\text{test} = 0$, Fin.
 Sinon, retourner à l'étape (2).

2.2.3 Avantages des K-means

- L'algorithme des K-means est simple à mettre en œuvre.
- L'algorithme est rapide, ce qui le rend adapté aux grands jeux de données où la CAH devient trop coûteuse en calcul.
- L'algorithme converge toujours vers une partition réalisant un maximum local de l'inertie inter-classe

2.2.4 Limites des K-means

- Le nombre de classes K doit être fixé au départ.
- L'algorithme ne permet pas de détecter les données aberrantes (outliers).
- Le résultat dépend fortement du choix initial des centres des groupe, généralement choisie de manière aléatoire, ce qui peut conduire à des solutions différentes.

2.3 DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*)

2.3.1 Principe

L'algorithme DBSCAN, acronyme de *Density-Based Spatial Clustering of Applications with Noise* (regroupement spatial basé sur la densité des applications avec bruit), a été proposé par Martin Ester, Hans-Peter Kriegel, Jörg Sander et Xiawei Xu en 1996.

Contrairement à l'algorithme des K-means, DBSCAN ne nécessite pas la fixation du nombre de classes K à l'avance. L'algorithme est basé sur la densité.

Il suppose que les classes sont des zones de forte densité séparées par des zones de plus faible densité, ce qui le rend capable d'identifier des classes de formes arbitraires et de détecter les données aberrantes (*outliers* ou bruit).

2.3.2 Paramètres clés et typologie des points

Les deux paramètres clés de l'algorithme sont :

- ϵ (**epsilon**) : la distance maximale définissant le voisinage d'un point.
 - **MinPts** (m) : le nombre minimal de points dans un voisinage de rayon ϵ pour former une région dense.
- Les deux paramètres sont fixés par l'utilisateur.

Soit (X, d) un espace métrique, muni de la distance euclidienne, et $\Omega = \{y_1, \dots, y_N\} \subset X$ un jeu de données composé de N observations.

Définition 4 (ε -voisinage). On appelle ε -voisinage d'un point y le sous-ensemble $V_\varepsilon(y) \subset \Omega$ défini par :

$$V_\varepsilon(y) = \{y' \in \Omega \mid d(y, y') < \varepsilon\} \quad (22)$$

c'est-à-dire l'ensemble des observations dont la distance à y est strictement inférieure à ε .

Définition 5 (m-densité). Le voisinage $V_\varepsilon(y)$ est dit m -dense s'il contient au moins m points, c'est-à-dire :

$$|V_\varepsilon(y)| \geq m. \quad (23)$$

Chaque point d'un jeu de données est alors classé dans l'une des trois catégories suivantes :

- **Les points centraux (core points) :** sont les points qui se trouvent au cœur d'un groupe ayant au moins MinPts dans leur voisinage ε ;
- **Les points frontières (border points) :** ce sont les points qui se trouvent à une distance ε d'un point central mais ne sont pas centraux eux-mêmes ;
- **Les points aberrants ou bruit (noise points) :** ce sont des points qui ne sont ni des points centraux, ni des points frontière. Ils sont considérés comme des données aberrantes et n'appartiennent à aucune classe.

Pour bien comprendre comment l'algorithme de DBSCAN forme des classes, il est essentiel de saisir deux concepts clés : **l'accessibilité et la connectivité par densité**.

Soient y et y' deux observations de Ω .

Définition 6 (Accessibilité directe par densité). Un point y' est dit directement accessible par densité depuis un point y par rapport aux paramètres ε et MinPts si :

- $y' \in V_\varepsilon(y)$
- $|V_\varepsilon(y)| \geq \text{MinPts}$

c'est à dire, y doit être un point central et y' doit se trouver dans son ε -voisinage.

Définition 7 (Accessibilité par densité). Un point y' est accessible par densité depuis un point y par rapport à ε et MinPts , s'il existe une suite de points $(x_1, x_2, \dots, x_n)$ telle que :

- $x_1 = y$ et $x_n = y'$
- x_{i+1} est directement accessible par densité depuis x_i , $\forall i \in \{1, \dots, n-1\}$

Définition 8 (Connectivité par densité). y est connecté par densité à y' par rapport à ε et MinPts , s'il existe un point $y_k \in \Omega$ tel que : y et y' sont accessibles tous deux par densité depuis y_k .

2.3.3 Algorithme

1. Fixer les valeurs de deux paramètres ε et MinPts
2. Choisir un point y n'ayant pas encore été visité.
3. Marquer y comme visité
4. Trouver tous les points situés à une distance inférieure ou égale à ε de y .
Ces voisins sont stockés dans une liste L .
5. Si le voisinage est dense (contient au moins MinPts points) :
 - (a) Un nouveau cluster est créé et y lui est assigné.
 - (b) Pour chaque élément y' de la liste L :
 - i. Marquer y' comme visité
 - ii. Si son propre voisinage est dense, on ajoute ses voisins à la liste L
 - iii. Si y' n'appartient encore à aucun groupe, on l'ajoute au cluster actuel.
6. Sinon, on marque y comme un point aberrant.
7. Répéter les étapes 1 à 5 jusqu'à ce que la totalité des points ait été visitée.

2.3.4 Choix des paramètres ε et MinPts

L'une des principales difficultés de l'algorithme DBSCAN consiste à choisir les paramètres ε et MinPts, dont dépend fortement son efficacité.

Choix de MinPts.

Voici quelques recommandations pour déterminer ce paramètre :

1. Une règle générale est :

$$\text{MinPts} = 2 \cdot p \quad \text{avec } p \text{ la dimension des données } (y_i \in \mathbb{R}^p)$$

2. Si ε est déjà choisi, on définit MinPts comme le nombre moyen de points dans les ε -voisinages :

$$\text{MinPts} = \frac{1}{N} \sum_{i=1}^N |V_\varepsilon(y_i)|$$

3. Dans la plupart des implémentations on pose par défaut : MinPts égale à 3, 4 ou 5.

Choix de ε .

On utilise le graphe des k -distance plot :

- On calcule pour chaque point sa distance à son k -ième plus proche voisin (où $k = \text{MinPts}$).
- On trie ces distances par ordre croissant et on trace la courbe obtenue.
- On choisit ε au niveau du coude de cette courbe, qui correspond à la transition entre les points denses (membres de clusters) et les points faibles denses (bruit).
En dessous du coude, les points forment des classes tandis qu'au-dessus ils sont considérés comme du bruit.

2.3.5 Avantages de DBSCAN

- DBSCAN ne nécessite pas de préciser le nombre de classes K au départ, celui-ci est une conséquence du choix des paramètres ε et MinPts.
- Il permet d'identifier les points aberrants, qui ne sont pas intégrés aux clusters.
- Il est capable de détecter des classes de formes arbitraires (non convexes).

2.3.6 Limites de DBSCAN

- Il est sensible au choix des paramètres MinPts et ε .
- Il peut rencontrer des difficultés à identifier des classes de densités très différentes.
- Ses performances diminuent en très grande dimension, notamment en raison de la dégradation de l'efficacité de la mesure de distance.
- Les données situées dans des zones de densité faible peuvent être considérées comme du bruit, alors qu'elles pourraient représenter des informations utiles.

3 Critères de validation

En classification non supervisée, l'évaluation des résultats représente un défi majeur. Deux questions principales se posent alors : comment mesurer la qualité de la partition obtenue, et comment déterminer le nombre optimal de classes K ?

Ainsi, l'évaluation repose sur des critères internes qui utilisent uniquement la structure des données et les propriétés géométriques de la partition.

Ces indices internes évaluent la qualité de la partition sans référence extérieure en s'appuyant exclusivement sur la structure des données : **méthode du coude**, **indice de silhouette**, **indice de Davies-Bouldin**.

3.1 Méthode du coude

La méthode du coude est l'outil le plus immédiat pour sélectionner le nombre de classes K dans l'algorithme K-means. Elle s'appuie directement sur le calcul de l'inertie intra-classe W définie en (9) qui mesure la compacité des clusters.

Par construction, W est une fonction décroissante de K : en augmentant le nombre de classes, on divise davantage le nuage de points et l'inertie intra-classe diminue mécaniquement.

L'objectif est alors d'identifier graphiquement un coude ou point d'inflexion marquant le nombre optimal de clusters k^* .

Ce point représente le compromis idéal entre la complexité du modèle et la qualité de la partition : au-delà de k^* , l'ajout de nouvelles classes ne fait que diviser des groupes déjà homogènes sans gain d'information significatif.

Cependant, cette méthode présente un défaut majeur : l'identification visuelle du coude est souvent difficile, en particulier lorsque la décroissance de W est régulière et ne présente pas de rupture franche. Par ailleurs, la méthode du coude ne s'applique pas directement aux méthodes hiérarchiques ou à DBSCAN.

3.2 Indice de silhouette

Contrairement à la méthode précédente qui se concentre uniquement sur la compacité, l'indice de Silhouette, introduit par Rousseeuw en 1987, évalue simultanément la cohésion d'un individu au sein de son propre cluster et sa séparation vis-à-vis des clusters voisins.

Pour chaque observation i , on calcule :

- La cohésion intra-classe $a(i)$: distance moyenne entre le point i et tous les autres points de son propre cluster C_k :

$$a(i) = \frac{1}{|C_k| - 1} \sum_{\substack{j \in C_k \\ j \neq i}} d(i, j) \quad (24)$$

- La séparation inter-classe $b(i)$: distance moyenne minimale de l'individu i aux individus de tout autre cluster :

$$b(i) = \min_{C_l \neq C_k} \left(\frac{1}{|C_l|} \sum_{j \in C_l} d(i, j) \right) \quad (25)$$

Le cluster réalisant ce minimum est appelé le cluster voisin de i .

L'indice de silhouette est défini par :

$$s_{sil}(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (26)$$

La valeur de l'indice est comprise entre -1 et 1 :

- Si $s_{sil}(i)$ est proche de 1 , cela signifie que l'individu i est bien classé.
- Si $s_{sil}(i)$ est proche de 0 , cela signifie l'individu i se situe à la frontière entre deux classes.
- Si $s_{sil}(i)$ est proche de -1 , cela signifie que l'individu i est mal classé.

Par ailleurs, on calcule l'indice de Silhouette global en moyennant les valeurs de $s_{sil}(i)$ sur l'ensemble des observations :

$$S_{sil}(K) = \frac{1}{n} \sum_{i=1}^n s_{sil}(i) \quad (27)$$

La valeur de K qui maximise $S_{sil}(K)$ correspond au nombre de classe optimal k^* .

Cet indice de silhouette présente l'avantage d'être interprétable à deux niveaux (à l'échelle de l'individu et de la partition globale) et d'être compatible avec toute mesure de distance, ce qui le rend applicable à l'ensemble des méthodes de clustering présentées en section 2.

Toutefois, son coût calculatoire, en $O(n^2)$, constitue sa principale limite, pouvant rendre son calcul complexe pour de grands jeux de données.

3.3 Indice de Davies-Bouldin

L'indice de Davies-Bouldin (S_{DB}), proposé par Davies et Bouldin en 1979, évalue la qualité d'une partition en mesurant, pour chaque paire de clusters, le rapport entre leur dispersion interne et leur séparation.

Il repose sur les quantités suivantes, définit pour chaque classe C_k :

— Dispersion interne de C_k :

$$\sigma_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} d(x_i, g_k) \quad (28)$$

Cette quantité mesure la distance moyenne des individus du cluster C_k à son centre de gravité g_k . C'est donc un indicateur d'homogénéité intra-classe.

— Indice de similarité entre deux clusters C_k et C_j :

$$R_{kj} = \frac{\sigma_k + \sigma_j}{d(g_k, g_j)} \quad (29)$$

Ainsi, l'indice de Davies est défini comme la moyenne du rapport maximal entre la distance d'un point au centre de son groupe et la distance entre deux centres de groupes :

$$S_{DB}(K) = \frac{1}{K} \sum_{k=1}^K \max_{l \neq k} R_{kl} \quad (30)$$

Contrairement à l'indice de Silhouette, l'indice de Davies-Bouldin est à minimiser : une valeur faible de $S_{DB}(K)$ traduit des clusters compacts et bien séparés.

Par conséquent, le nombre optimal k^* est celui qui minimise $S_{DB}(K)$.

De plus, l'indice de Davies-Bouldin est moins coûteux en calcul, $O(nK)$, que l'indice de Silhouette et offre une interprétation géométrique directe. Il tend à favoriser les clusters convexes et de taille comparable, ce qui peut le rendre moins pertinent dans certaines configurations, notamment avec DBSCAN où les clusters peuvent prendre des formes arbitraires.

Les critères présentés constituent les outils essentiels pour évaluer la qualité d'une partition et sélectionner le nombre optimal de classes K . Leur choix dépend de la méthode de clustering utilisée, de la forme des clusters attendus et des contraintes calculatoires.

Néanmoins, ces critères présentent certaines limites. En particulier, aucun indice ne permet de garantir, de manière universelle, l'identification du meilleur clustering.

De plus, ces mesures reposent fortement sur le choix de la distance, ce qui peut influencer significativement les résultats et conduire, dans certains cas, à des conclusions différentes.

Dans ce contexte, il est recommandé de combiner au moins deux critères d'évaluation et d'interpréter les résultats avec précaution, en tenant compte des spécificités des données étudiées.

4 Mise en application sur une base de données

Cette partie applique trois méthodes de classification non supervisée présentées en section 2, à un jeu de données. L'objectif est d'obtenir des classes homogènes, puis de comparer les partitions produites par chacune des trois méthodes.

Par ailleurs, avant la classification, une analyse en composantes principales est effectuée. Son rôle est double : d'une part, vérifier l'existence d'une structure dans les données susceptible d'être mise en évidence par les méthodes de clustering ; d'autre part, fournir un plan de représentation bidimensionnel commun dans lequel les résultats de chaque classification seront projetés, rendant ainsi possible une comparaison visuelle directe entre les méthodes.

4.1 Présentation et traitement du jeu de données

Le jeu de données utilisé est le dataset *Decathlon*. Cette épreuve est composée de 10 disciplines différentes : course, lancer de poids, saut à la perche, etc. Il regroupe les performances de 41 athlètes ayant participé à deux compétitions de décathlon : les Jeux Olympiques et le Decastar.

Chaque athlète est évalué sur l'ensemble des disciplines et un score total est calculé.

Il convient de noter que les résultats des disciplines ne s'interprètent pas toutes dans le même sens : pour les épreuves chronométrées (100m, 400m, 110m haies et 1500m), une valeur moyenne élevée traduit un temps long et donc une moins bonne performance, tandis que pour les épreuves de saut (longueur, hauteur, perche) et de lancer (poids, disque, javelot), une valeur élevée reflète au contraire une meilleure performance.

La base de données comporte 41 observations représentant les athlètes et 13 variables réparties comme suit :

TABLE 4 – *Decathlon* : Statistiques descriptives des variables

Variables	Unité	Min.	Médiane	Moyenne	Max.	Type
100 m	secondes	10,44	10,98	11,00	11,64	Quant. continue
Longueur	mètres	6,61	7,30	7,26	7,96	Quant. continue
Poids	mètres	12,68	14,57	14,48	16,36	Quant. continue
Hauteur	mètres	1,85	1,95	1,977	2,15	Quant. continue
400 m	secondes	46,81	49,40	49,62	53,20	Quant. continue
110 m haies	secondes	13,97	14,48	14,61	15,67	Quant. continue
Disque	mètres	37,92	44,41	44,33	51,65	Quant. continue
Perche	mètres	4,20	4,80	4,76	5,40	Quant. continue
Javelot	mètres	50,31	58,36	58,32	70,52	Quant. continue
1500 m	secondes	262,1	278,1	279,0	317,0	Quant. continue
Points	entier	7313	8021	8005	8893	Quant. discrète
Classement	entier	1	11	12,12	28	Quant. discrète
Compétition	catégorielle	JO = 28 et Decastar = 13				Qual. nominale

Avant toute analyse, on va retirer les variables quantitatives discrètes (points et classement) car elles sont calculées à partir des résultats aux dix disciplines. Les inclure reviendrait à rajouter des informations qui biaiserait le résultat des classifications.

De plus, les variables quantitatives continues (les dix disciplines) présentent des unités différentes : les temps de courses sont exprimés en seconde tandis que les distances des lancers et sauts sont en mètres. Une standardisation (section 1.2) est donc indispensable afin d'éviter qu'une variable ayant une grande variance domine le calcul des distances euclidiennes. Chaque variable quantitative continue est donc centrée et réduite à l'aide de la fonction *scale()* de R, ce qui garantit une contribution équitable de chacune des disciplines à l'analyse.

Avant d'appliquer l'ACP et les méthodes de classification, il est utile d'étudier les relations entre les dix variables quantitatives. Pour cela on utilise la matrice des corrélations :

TABLE 5 – *Décathlon* : Matrice des corrélations entre les variables

	X100m	Longueur	Poids	Hauteur	X400m	X110m.H	Disque	Perche	Javelot	X1500m
X100m	1.00	-0.60	-0.36	-0.25	0.52	0.58	-0.22	-0.08	-0.16	-0.06
Longueur	-0.60	1.00	0.18	0.29	-0.60	-0.51	0.19	0.20	0.12	-0.03
Poids	-0.36	0.18	1.00	0.49	-0.14	-0.25	0.62	0.06	0.37	0.12
Hauteur	-0.25	0.29	0.49	1.00	-0.19	-0.28	0.37	-0.16	0.17	-0.04
X400m	0.52	-0.60	-0.14	-0.19	1.00	0.55	-0.12	-0.08	0.00	0.41
X110m.H	0.58	-0.51	-0.25	-0.28	0.55	1.00	-0.33	0.00	0.01	0.04
Disque	-0.22	0.19	0.62	0.37	-0.12	-0.33	1.00	-0.15	0.16	0.26
Perche	-0.08	0.20	0.06	-0.16	-0.08	0.00	-0.15	1.00	-0.03	0.25
Javelot	-0.16	0.12	0.37	0.17	0.00	0.01	0.16	-0.03	1.00	-0.18
X1500m	-0.06	-0.03	0.12	-0.04	0.41	0.04	0.26	0.25	-0.18	1.00

D'après cette sortie, on remarque qu'il y a des corrélations positives et négatives.

Les corrélations positives sont :

- Le 100m est fortement corrélé avec le 110m haies (0,58) et le 400m (0,52). Les trois épreuves étant des courses chronométrées, un athlète rapide dans l'une des disciplines sera également performant dans les autres.
- Le poids est corrélé avec le disque (0,62), cela signifie que les athlètes performants au lancer du poids sont également performants au lancer du disque, car ces deux disciplines nécessitent des qualités physiques similaire. Il est aussi faiblement corrélé au javelot (0,37) et à la hauteur (0,49), ce qui suggère qu'une bonne puissance physique aide dans plusieurs disciplines.
- Le 1500m est faiblement corrélé avec le 400m (0,41).

Les corrélations négatives sont :

- Le saut en longueur est corrélé avec le 100m (-0,60), 400m (-0,60), et au 110m haies (-0,51). En considérant ces coefficients en valeur absolue, cela montre qu'un athlète performant au saut en longueur est également performant dans les épreuves de course.
- Le 100m est faiblement corrélé avec le poids (-0,36) et le 110m haies avec le disque (-0,33), cela signifie qu'avoir de la puissance aide dans les épreuves de vitesse.

4.2 Analyse en Composantes Principales

4.2.1 Choix du nombre de composantes

Le choix du nombre de composantes principale est guidé par la règle de Kaiser et le scree plot (section 1.5.2). D'après nos sorties R, on a le tableau suivant :

TABLE 6 – ACP : Valeurs propres et variance expliquée par composante principale

Composante	Valeur propre	% variance	% cumulé	Kaiser (> 1)	Décision
CP1	3,27	32,72 %	32,72 %	✓	Retenue
CP2	1,74	17,37 %	50,09 %	✓	Retenue
CP3	1,40	14,05 %	64,14 %	✓	Retenue
CP4	1,06	10,57 %	74,71 %	✓	Retenue
CP5	0,68	6,85 %	81,56 %	×	Rejetée
CP6	0,60	5,99 %	87,55 %	×	Rejetée
CP7	0,45	4,51 %	92,06 %	×	Rejetée
CP8	0,40	3,97 %	96,03 %	×	Rejetée
CP9	0,21	2,15 %	98,18 %	×	Rejetée
CP10	0,18	1,82 %	100,00 %	×	Rejetée

On remarque que la règle de Kaiser conduit à retenir quatre composantes principales dont la variance totale du jeu de données atteint 74,71%. Les deux premières composantes expliquent à elles seules 50,09% de variance ce qui justifie leur utilisation comme plan de représentation pour la visualisation des individus et des variables. Ce choix est confirmé avec le scree plot qui révèle un coude net dès la deuxième composante principale.

FIGURE 6 – ACP : Scree plot





FIGURE 7 – ACP : Scree plot avec variance expliquée



4.2.2 Interprétations des axes

L'interprétation des axes repose sur les coordonnées des variables qui représentent directement les corrélations entre chaque variable originale et chaque composante principale.

FIGURE 8 – ACP : cercle des corrélations




TABLE 7 – ACP : Corrélations des variables avec CP1 et CP2) (%)

Variable	CP1 (%)	CP2 (%)
100m	-0.77	0.19
Longueur	0.74	-0.35
Poids	0.62	0.60
Hauteur	0.57	0.35
400m	-0.68	0.57
110m haies	-0.75	0.23
Disque	0.55	0.61
Perche	0.05	-0.18
Javelot	0.28	0.32
1500m	-0.06	0.47

- **Le premier axe (CP1 avec 32,72% de variance) :** est structuré par les variables présentant les corrélations les plus élevées en valeur absolue. Du côté négatif : le 100m (-0.77), le 110m haies (-0.75) et le 400m (-0.680), trois épreuves chronométrées pour lesquelles une valeur élevée correspond à un temps long, donc à une moins bonne performance. Du côté positif; la longueur (0.74), la hauteur (0.57), le poids (0.62) et le disque (0.55), disciplines pour lesquelles une bonne valeur traduit une bonne performance. Ainsi, sur cet axe les athlètes présentant des coordonnées positives sont rapides et performants tandis que ceux avec des coordonnées négatives le sont moins.

La perche et le 1500m ont des corrélations quasi-nulles.

- **Le deuxième axe (CP2 avec 17,37% de variance) :** est corrélé positivement avec le disque (0.61), le poids (0.60), le 400m (0.57) et le 1500m (0.47) et négativement avec la longueur (-0.35) et la perche. Cette composante oppose les athlètes performants dans les épreuves de disque et de 400m à ceux performants en longueur, elle peut donc être interprétée comme un axe de lancer et d'endurance.

De plus, on remarque que certaines variables sont très proches (100m/ 100m haies, poids/disque, etc) cela confirme le résultat donnée par la matrice des corrélations. (5).

Les variables proches les unes des autres dans le cercle sont positivement corrélées, celles opposées sont négativement corrélées, et celles presque perpendiculaires sont faiblement corrélées. Aussi, la perche est une discipline très indépendante des autres, elle n'est pas bien représentée par les deux premières composantes (0.05 pour CP1 et -0.18 pour CP2).

Notons également, que toutes les variables ne contribuent pas de façon équivalente à la construction des composantes. En supposant la participation uniforme, le seuil de contribution moyen est de 10%. Toutes

variables au-dessus de ce seuil contribuent le plus aux deux composantes retenues.

FIGURE 9 – ACP : Contribution des variables à (CP1,CP2)





TABLE 8 – ACP : Contributions des variables à (CP1,CP2)

Variable	CP1 (%)	CP2 (%)
100m	18,34	2,02
Longueur	16,82	6,87
Poids	11,84	20,61
Hauteur	10,00	7,06
400m	14,12	18,67
110m haies	17,02	3,01
Disque	9,33	21,16
Perche	0,08	1,87
Javelot	2,35	5,78
1500m	0,10	12,95

4.2.3 Projection des individus et qualité de représentation

La projections des 41 athlètes dans le plan (CP1,CP2) permet une lecture visuelle de leur répartition.

FIGURE 10 – ACP : projection des individus



Dans ce plan, les athlètes se répartissent, créant une légère séparation. Les athlètes les plus performant comme Sebrle, Clay et Karpov se retrouvent à droite confirmant l'interprétation de cet axe, tandis que les athlètes les moins compétitifs se situent dans la partie gauche du graphique.

De plus, la qualité de représentation d'un individu dans le plan (CP1,CP2) est mesurée par son $\cos^2$. Un $\cos^2$ proche de 1 indique que l'individu est fidèlement représenté dans le plan ; proche de 0, il est mal restitué et son profil de performance est davantage capturé par les composantes CP3 ou CP4.

FIGURE 11 – ACP : Qualité de représentation ($\cos^2$)




TABLE 9 – ACP : Top 10 des athlètes selon leur qualité de représentation dans le plan (CP1,CP2) ($\cos^2$)

Athlète	$\cos^2$ CP1	$\cos^2$ CP2
Casarsa	0,34	0,60
Warners	0,53	0,37
BOURGUIGNON	0,86	0,00
Karpov	0,85	0,00
Drews	0,01	0,81
Sebrle	0,70	0,08
Uldal	0,76	0,01
Clay	0,71	0,03
NOOL	0,39	0,28
Lorenzo	0,47	0,20

Ici, la qualité de représentation moyenne s'élève à 0,407, ce qui signifie que le plan factoriel restitue en moyenne 40,8 % de la variabilité individuelle, valeur cohérente avec 50,09% de variance totale des deux composantes.

Les athlètes les mieux représentés sont : Casarsa(0,94), Warners(0,90), Bourguignon(0,86) et Karpov(0,85), leur position dans le plan peut être interprétée avec confiance. À l'inverse, plusieurs athlètes présentent une qualité de représentation très faible dans ce plan : Schoenbeck (0,005), Barras (0,026), Terek (0,070) et McMullen (0,061) sont quasi invisibles dans l'espace (CP1,CP2). Toutefois, cela ne signifie pas qu'ils sont atypiques, mais que leur profil de performance est principalement structuré par CP3 ou CP4 et ne peut donc pas être interprété à partir du seul plan principal.

Notons également, le seuil de contribution moyen est de 2,44% pour les individus.

FIGURE 12 – ACP : Contribution des individus à (CP1,CP2)





TABLE 10 – ACP : Contributions des individus à (CP1,CP2) (Top 15)

Athlète	CP1 (%)	CP2 (%)
Casarsa	6.09	20.25
Karpov	15.91	0.00
Sebrle	12.16	2.62
Clay	11.45	0.98
BOURGUIGNON	11.80	0.06
Drews	0.05	13.33
NOOL	4.10	5.43
Lorenzo	4.32	3.52
Warners	3.51	4.57
Uldal	4.89	0.08
Macey	3.72	1.52
Parkhomenko	0.85	6.15
Korkizoglou	0.68	6.00
YURKOV	0.26	6.38
MARTINEAU	2.97	0.44

Par ailleurs, en faisant une répartition des individus avec la variable compétition qui a été retirée précédemment, on remarque que les ellipses représentées pour chaque groupe se chevauchent ce qui indique que le plan (CP1,CP2) ne sépare pas les groupes par rapport aux deux compétitions (Jo et Decastar).

FIGURE 13 – ACP : Répartition des athlètes par compétition




Les deux groupes présentent donc des profils comparables dans cet espace réduit et la différences entre les athlètes réside dans la composition interne des groupes.

Ainsi, l'ACP révèle une structure interne au jeu de données organisée autour de deux dimensions principales. La première, dominante, oppose les bons athlètes aux moins performants, et la deuxième distinguent des profils de spécialisation (lancer, endurance).

4.3 Classification Ascendante Hiérarchique

La Classification Ascendante Hiérarchique est appliquée sur les dix variables standardisées avec le critère d'agrégation de Ward et la distance euclidienne. Cette méthode construit une hiérarchie complète des regroupements, par un dendrogramme.

FIGURE 14 – CAH : dendrogramme



4.3.1 Choix du nombre de classes

Le choix du nombre de classes repose sur deux critères graphiques complémentaires.

Le saut d'inertie, obtenu à partir des hauteurs de fusion du dendrogramme, révèle les fusions les plus coûteuses en termes d'homogénéité.

Le graphique montre un saut marqué entre la cinquième et la sixième fusion, ce qui suggère un premier découpage possible en cinq classes. Toutefois, un second saut, moins prononcé, est observable entre la quatrième et la troisième fusion, orientant vers un découpage en quatre classes.

La méthode des silhouettes, calculée pour K allant de 2 à 10, atteint son maximum local à $K = 6$.

Les deux critères ne convergent donc pas vers une valeur unique de K . Dans ce cas, le choix de K est guidé par un critère d'interprétabilité. Le découpage en 4 classes est retenue afin d'obtenir un effectif suffisant dans chaque classe.

FIGURE 15 – CAH : Saut d'inertie





FIGURE 16 – CAH : Méthode des silhouettes



4.3.2 Description et interprétations des classes

D'après nos sorties R, on a :

FIGURE 17 – CAH : Clusters dans (CP1,CP2)




TABLE 11 – CAH : Répartition des 41 athlètes dans les quatre classes

Classe	Athlètes
1	Sebrle, Clay, Karpov
2	Macey, Warners, Hernu, Nool Bernard, Schwarzl, Schoenbeck, Barras Smith, Averyanov, Ojaniemi, Smirnov Qi, Drews, Gomez, BERNARD WARNERS, ZSIVOCZKY, McMULLEN
3	Zsivoczky, Pogorelov, Parkhomenko, Terek Turi, Korkizoglou, Casarsa, SEBRLE CLAY, KARPOV, YURKOV
4	Lorenzo, Karlivans, Uldal, MARTINEAU HERNU, BARRAS, NOOL, BOURGUIGNON

L'analyse descriptive des profils moyens par classe, présentée dans le tableau ci-dessous, constitue une première lecture des caractéristiques de chaque groupe. Ces moyennes obtenues permettent d'observer des tendances générales entre les classes, mais ne suffisent pas à déterminer quelles différences sont statistiquement significatives.

TABLE 12 – CAH : Profil descriptif des classes (valeurs non standardisées)

Variable	Classe 1	Classe 2	Classe 3	Classe 4
100m (s)	10,596	10,897	11,034	11,336
Longueur (m)	7,870	7,333	7,093	7,086
Poids (m)	15,840	14,375	14,877	13,657
Hauteur (m)	2,090	1,967	2,011	1,908
400m (s)	48,120	49,116	50,435	50,238
110m haies (s)	14,050	14,415	14,719	15,110
Disque (m)	50,160	43,432	45,634	42,458
Perche (m)	4,833	4,730	4,843	4,700
Javelot (m)	65,256	58,181	58,312	56,040
1500m (s)	280,040	273,186	290,763	276,368

On introduit alors la fonction *catdes()* afin d'avoir une caractérisation statistique.

Cette analyse identifie pour chaque classe les variables dont la moyenne diffère significativement de la moyenne globale. Les résultats sont présentés dans le tableau suivant :

TABLE 13 – CAH : Description statistique des quatre classes par variables quantitatives

Classe	Variable	v.test	Moy. classe	Moy. globale	p-valeur
Classe 1 ($n = 3$)	Longueur	3,468	7,87	7,26	0.0005
	Disque	3,107	50,16	44,325	0.0018
	Poids	2,974	15,84	14,477	0.0029
	Javelot	2.586	65.256	58.316	0.0096
	Hauteur	2,289	2,09	1,976	0.0220
	110m haies	-2,119	14,05	14,605	0.0340
	400m	-2.333	48.120	49.616	0.0195
	100m	-2.745	10.596	10.998	0.0060
Classe 2 ($n = 19$)	100m	-2.265	10,897	10,998	0.0234
	110m haies	-2.397	14,415	14,605	0.0165
	400m	-2,579	49,116	49,616	0.0098
	1500m	-2.975	273,186	279,024	0,0029
Classe 3 ($n = 11$)	1500m	3,899	290,763	279,024	9.66×10^{-5}
	400m	2.753	50,354	49,616	5.90×10^{-3}
	Longueur	-2.038	7,093	7,26	4.15×10^{-2}
Classe 4 ($n = 8$)	100m	4,053	11,336	10,998	5.04×10^{-5}
	110m haies	3,368	15,110	14,605	7.55×10^{-4}
	Hauteur	-2,412	1,908	1,976	1.58×10^{-2}
	Poids	-3,134	13,657	14,477	1.72×10^{-3}

C'est sur la base de ce résultat que chaque classe est décrite ci-après.

- **La classe 1** : regroupe trois athlètes des JO (Sebrle, Clay et Karpov) dont les performances moyennes dominent sur la quasi-totalité des disciplines. Elle se distingue significativement par d'excellents résultats en longueur (7,87 m contre 7,26 m), au disque (50,16 m contre 44,33 m), au poids (15,84 m contre 14,48 m) et à la hauteur (2,09 m contre 1,98 m), ainsi que par des temps nettement inférieurs à la moyenne au 100 m (10,60 s), au 400 m (48,12 s) et au 110 m haies (14,05 s). Avec en moyenne un score de 8 813 points, ce sont les médaillés des jeux olympiques. Leur profil est celui d'un athlète complet, dominant aussi bien les épreuves de vitesse que les épreuves de lancer et de saut. Dans le plan ACP, ils se positionnent à l'extrémité droite de CP1 confirmant leur statut d'athlètes les plus performants de l'ensemble du jeu de données.
- **La classe 2** : regroupe des athlètes assez performants issus des deux compétitions (JO et DECASTAR) avec un score moyen de 8 082 points. Elle se caractérise par des temps significativement inférieurs à la moyenne sur l'ensemble des épreuves de course : le 1500m (273,19 s contre 279,02 s), le 400m (49,12 s contre 49,62 s), le 110m haies (14,42 s contre 14,61 s) et le 100m (10,90 s contre 11,00 s). On peut alors affirmer que le point fort de ce groupe réside dans sa vitesse et son endurance. Notons, aussi que le 1500m est la variable la plus significative de cette classe avec un *v.test* de -2,975. Dans le plan ACP, cette classe occupe une position centrale positive sur CP1, cohérente avec un niveau de performance correct mais sans dominance marquée sur un axe particulier.
- **La classe 3** : avec un score moyen de 7 940 points, présente un profil faible et homogène. Trois variables la caractérisent significativement. Les temps au 1500 m (290,76 s contre 279,02 s) et au 400 m (50,44 s contre 49,62 s) sont nettement supérieur à la moyenne, de plus le saut en longueur est en dessous de la moyenne (7,09 m contre 7,26 m). Dans le plan ACP, ces athlètes se répartissent dans une zone centrale légèrement négative sur CP1, cohérente avec un niveau de performance global inférieur aux classes 1 et 2.
- **La classe 4** : avec un score moyen de 7 610 points, est majoritairement composée d'athlètes du Decastar. La caractérisation statistique révèle quatre variables significatives. Les temps au 100 m (11,34 s contre 11,00 s) et au 110 m haies (15,11 s contre 14,61 s) sont supérieurs à la moyenne, tandis que la hauteur (1,91 m contre 1,98 m) et le poids (13,66 m contre 14,48 m) sont inférieurs à la moyenne. Cette classe présente le niveau de performance globale le plus faible de l'ensemble du jeu

de données. Dans le plan ACP, ces athlètes se positionnent à l’extrémité gauche de CP1, à l’opposé de la classe 1, ce qui est pleinement cohérent avec l’interprétation de cet axe.

4.3.3 Qualité de représentation

La qualité de la partition en quatre classes est évaluée à l’aide de deux indicateurs complémentaires : la silhouette et le coefficient agglomératif.

D’après nos sorties R, on a :

FIGURE 18 – CAH : Qualité de représentation




TABLE 14 – CAH : Silhouette moyenne par classe

Classe	Effectif	Silhouette moyenne
1	3	0,327
2	19	0,147
3	11	-0.005
4	8	0,207
Total	41	0.131

La silhouette moyenne de la partition s’élève à 0,131. Cette valeur, globalement faible, est cohérente avec les caractéristiques du jeu de données (41 individus dans un espace de dix dimensions).

De plus, l’analyse par classes relève des différences importantes. La classe 1 présente la meilleure cohésion interne ($s_{sil}(3) = 0,327$), ce qui est attendu pour un groupe de trois athlètes d’élite bien isolés dans l’espace des performances. La classe 4 affiche une silhouette de 0,207, traduisant une bonne homogénéité interne du groupe des athlètes les moins performants. La classe 2 présente une silhouette modérée de 0,147, tandis que la classe 3 affiche une valeur négative de $-0,005$, indiquant une frontière floue avec les classes voisines (principalement avec la classe 2), ce qui est cohérent avec la description faite dans la section 4.3.2.

La partition est par ailleurs confirmée par le coefficient agglomératif qui s’élève à 0,76 ce qui atteste d’une structure hiérarchique bien définie (une valeur supérieure à 0,75 est généralement considérée comme indicatrice d’une bonne cohésion).

4.4 Classification par K-means

La classification par K-means est appliquée aux données standardisées via la fonction `kmeans()` de R, avec la distance euclidienne. L’initialisation des centroïdes étant aléatoire, la valeur initiale est fixée avec `set.seed(123)` et 25 initialisations sont effectuées (`nstart = 25`) afin de garantir la reproductibilité et la stabilité du résultat.

4.4.1 Choix du nombre de classes

Le choix du nombre de classes repose sur deux critères graphiques obtenus avec la méthode du coude et la méthode des silhouettes.

FIGURE 19 – K-means : Méthode du coude





FIGURE 20 – K-means : Méthode des silhouettes



La méthode du coude représente l'inertie intra-classe totale W en fonction de K . Elle indique une décroissance progressive de l'inertie intra-classe sans rupture franche. Néanmoins, le gain marginal apporté par chaque classe supplémentaire diminue à partir de $K = 4$, orientant vers un découpage en quatre classes.

La méthode des silhouettes indique quant à elle un maximum à $K = 2$. La situation est identique à celle rencontrée pour la CAH : les deux critères ne convergent pas vers le même K .

Ainsi, pour les mêmes raisons d'interprétabilité, et afin de permettre une comparaison directe avec la CAH, la partition en quatre classes est retenue.

4.4.2 Description et interprétation des classes

D'après nos sorties R, on a :

FIGURE 21 – K-means : Clusters dans (CP1,CP2)




TABLE 15 – K-means : Répartition des 41 athlètes dans les quatre classes

Classe	Athlètes
1	Parkhomenko, Turi, Lorenzo , Karlivans Korkizoglou, Udal, Casarsa, YURKOV MARTINEAU, HERNU, BARRAS, NOOL BOURGUIGNON
2	Sebrle, Clay, Karpov
3	Warners, Nool, Schwarzl Pogorelov, Schoenbeck, Averyanov, Drews Terek, SEBRLE, CLAY, KARPOV, BERNARD, WARNERS
4	Macey,Zsivoczky, Hernu, Bernard Barras, Smith, Ojaniemi, Smirnov, Qi Gomez, ZSIVOCZKY, McMULLEN

On remarque que K-means produit une partition aux effectifs nettement plus équilibrée que la CAH : 13, 3, 13 et 12 athlètes contre 3, 19, 11 et 8.

De plus, l'analyse descriptive des profils moyens par classe et la caractérisation statistique , présentées dans les tableau ci-dessous, permettent de décrire les quatres classes.

TABLE 16 – K-means : Profil descriptif des classes (valeurs non standadisées)

Variable	Classe 1	Classe 2	Classe 3	Classe 4
100m (s)	11,266	10,596	10,887	10,926
Longueur (m)	7,003	7,807	7,395	7,238
Poids (m)	14,114	15,840	14,438	14,570
Hauteur (m)	1,946	2,090	1,950	2,009
400m (s)	50,723	48,120	49,275	49,160
110m haies (s)	15,052	14,050	14,398	14,485
Disque (m)	43,260	50,160	43,709	44,688
Perche (m)	4,693	4,833	5,046	4,511
Javelot (m)	57,583	65,256	56,325	59,532
1500m (s)	282,186	280,040	283,198	270,825

TABLE 17 – K-means : Description statistique des quatre classes par variables quantitatives

Classe	Variable	v.test	Moy. classe	Moy. globale	p-valeur
Classe 1 ($n = 13$)	100m	4.460	11.267	10.998	8.19×10^{-6}
	400m	4.186	50.723	49.616	2.84×10^{-5}
	110m haies	4.129	15.052	14.606	3.65×10^{-5}
	Longueur	-3.532	7.004	7.260	4.12×10^{-4}
Classe 2 ($n = 3$)	Longueur	3.469	7.870	7.260	0.0005
	Disque	3.108	50.160	44.326	0.0018
	Poids	2.974	15.840	14.477	0.0029
	Javelot	2.587	65.257	58.317	0.0096
	Hauteur	2.289	2.090	1.977	0.0220
	110m haies	-2.120	14.050	14.606	0.0340
	400m	-2.334	48.120	49.616	0.0195
	100m	-2.746	10.597	10.998	0.0060
Classe 3 ($n = 13$)	Perche	4.453	5.046	4.762	8.48×10^{-6}
Classe 4 ($n = 12$)	1500m	-2.893	270.825	279.025	0.0038
	Perche	-3.716	4.512	4.762	0.0002

- **La classe 1** : avec un score moyen de 7 655 points, est comparable à la classe 4 de la CAH, mais avec un effectif plus élevé (13 contre 8). Le K-means y intègre des athlètes qui étaient classés en classe 3 par la CAH (Parkhomenko, Turi, Korkizoglou, Casarsa, YURKOV). Elle est caractérisée par quatre variables, toutes défavorables : des temps significativement supérieurs à la moyenne au 100 m (11,27 s contre 11,00 s), au 400 m (50,72 s contre 49,62 s) et au 110 m haies (15,05 s contre 14,61 s), ainsi

qu'un saut en longueur inférieur (7,00 m contre 7,26 m). Ce groupe rassemble donc les athlètes les moins performants en vitesse et en saut.

- **La classe 2** : est identique à la classe 1 de la CAH, mêmes athlètes, mêmes variables caractéristiques. Cela confirme leur stabilité dans l'espace des performances.
- **La classe 3** : avec un score moyen de 8 094 points, regroupe huit athlètes de classe 2 de la CAH et cinq athlètes de la classe 3 de la CAH. Elle est caractérisée par une seule variable significative : la perche (5,05 m contre 4,76 m), nettement supérieure à la moyenne. De plus, le K-means isole ainsi un profil spécialiste de la perche, que la CAH avait masqué dans un groupe plus large.
- **La classe 4** : avec un score moyen de 8 088 points, est définie par deux variables. Le 1500 m est significativement inférieur à la moyenne (270,82 s contre 279,02 s) : ce temps plus court révèle d'excellentes aptitudes en endurance. À l'inverse, la perche est nettement en dessous de la moyenne (4,51 m contre 4,76 m), à l'opposé exact de la classe 3. C'est précisément cette discipline qui sépare géométriquement ces deux groupes.

4.4.3 Qualité de représentation

FIGURE 22 – K-means : Qualité de représentation




TABLE 18 – K-means : Silhouette moyenne par classe

Classe	Effectif	Silhouette moyenne
1	13	0,060
2	3	0,303
3	13	0,133
4	12	0,195
Total	41	0.141

La silhouette moyenne s'élève à 0,141, légèrement supérieure à celle de la CAH (0,131), et le pourcentage de variance expliquée atteint 39,507 % (rapport entre inertie-inter B et inertie totale T). La classe 2 présente la meilleure cohésion (0,303), confirmant l'isolement net des trois élites. La classe 4 affiche une silhouette correcte de 0,195, validant la pertinence du profil endurant identifié par le K-means. La classe 3 présente une valeur modérée (0,133), cohérente avec la diversité de composition de ce groupe. La classe 1 affiche la valeur la plus faible (0,060), traduisant une séparation moins nette avec les classes voisines ce qui s'explique par sa composition qui intègre des athlètes issus de deux classes distinctes de la CAH aux profils partiellement similaires.

4.5 Classification par DBSCAN

DBSCAN est appliqué aux données standardisées à l'aide de la fonction `dbscan()` de R.

4.5.1 Choix des paramètres ε et MinPts

Le succès de l'algorithme repose sur le choix du rayon de voisinage ε et le nombre minimal de points MinPts nécessaire pour former une région dense.

Dans un premier temps, DBSCAN est appliqué sur les dix variables standardisées, avec `MinPts` = 4.

Le paramètre ε est déterminé à l'aide du *k-NN distance plot*, qui représente, pour chaque point, la distance à son k -ième plus proche voisin (ici $k = 4$), triée par ordre croissant (voir section 2.3.4).

FIGURE 23 – DBSCAN : 4-NN distance plot sur les données standardisées




TABLE 19 – DBSCAN : Résultats selon ε sur les données standardisées (MinPts = 4)

ε	Nombre de classes	Points bruit
2,5	1	20
3,0	1	8
3,5	1	4
4,0	1	0

Les distances des 4-plus proches voisins augmentent de manière relativement progressive, et ne présente pas de coude net permettant d'identifier une valeur de ε . Ce constat est confirmé par les résultats obtenus pour plusieurs valeurs de ε (voir table 19).

Pour l'ensemble des valeurs de ε testées, DBSCAN ne détecte qu'une seule classe. Ce résultat s'explique par le fait que dans un espace à dix dimensions avec seulement 41 individus, les distances inter-individus s'homogénéisent, rendant difficile la distinction entre les régions denses et celles peu denses. L'algorithme n'est donc pas adapté à ce jeu de données dans l'espace original des variables.

Pour contourner cette limite observée en dimension dix, DBSCAN est appliqué sur les coordonnées des individus dans le plan des deux premières composantes principales (CP1,CP2). Ce plan fournit un espace réduit concentrant l'information principale du jeu de données où les densités locales sont mieux définies. Ce choix est confirmé par les résultats obtenus dans la table 20.

On fixe le paramètre MinPts à 3 (recommandée pour des données de faible dimension). Le *k-NN distance plot* ($k = 3$) dans cet espace montre un coude plus marqué aux alentours de $\varepsilon \approx 1,5$, valeur retenue pour la suite.

FIGURE 24 – DBSCAN : 3-NN distance plot sur (CP1,CP2)




TABLE 20 – DBSCAN : Résultats selon ε sur (CP1,CP2) (MinPts $k = 3$)

ε	Nombre de classes	Points bruit
1,5	3	3
2,0	1	1
2,5	1	0
4,0	1	0

On remarque que seul $\varepsilon = 1,5$ produit une partition en trois clusters. Pour les autres valeurs de ε , les clusters forment un groupe unique, ce qui signifie que la séparation entre les groupes n'est plus suffisamment marquée pour être identifiée.

Donc, les paramètres retenus sont $\varepsilon = 1,5$ et MinPts = 3, appliqués sur le plan (CP1,CP2).

4.5.2 Interprétations des classes

D'après nos sorties R, on a :

FIGURE 25 – DBSCAN : Clusters dans (CP1,CP2)
($\varepsilon = 1.5$ et $MinPts = 3$)




TABLE 21 – DBSCAN : Répartition des
41 athlètes dans les quatre classes et les
points de bruit

Classe	Athlètes
1	Sebrle, Clay, Karpov
2	Macey, Zsivoczky, Hernu, Nool Bernard, Schwarzl, Pogorelov, Schoen- beck Barras, Smith, Averyanov, Ojaniemi Smirnov, Qi, Terek, Gomez Turi, Lorenzo, Karlivans, Uldal SEBRLE, CLAY, KARPOV, BER- NARD WARNERS, ZSIVOCZKY, McMUL- LEN, MARTINEAU HERNU, BARRAS, NOOL, BOUR- GUIGNON
3	Parkhomenko, Korkizoglou, YURKOV
Bruit (0)	Warners, Drews, Casarsa

DBSCAN identifie trois classes et trois points de bruit, résultat structurellement différent de ceux obtenus par la CAH et le K-means qui produisaient tous deux quatre classes sans bruit.

TABLE 22 – DBSCAN : Profil descriptif des classes (valeurs non standardisées)

Variable	Classe 1	Classe 2	Classe 3
100m (s)	10,596	11,029	11,113
Longueur (m)	7,870	7,234	6,923
Poids (m)	15,840	14,309	15,230
Hauteur (m)	2,090	1,966	2,023
400m (s)	48,120	49,613	50,873
110m haies (s)	14,050	14,629	15,050
Disque (m)	50,160	43,754	44,743
Perche (m)	4,833	4,758	4,740
Javelot (m)	65,257	57,730	60,770
1500m (s)	280,040	277,506	290,447

TABLE 23 – DBSCAN : Description statistique des trois classes par variables quantitatives

Classe	Variable	v.test	Moy. classe	Moy. globale	p-valeur
Classe 1 ($n = 3$)	Longueur	3,469	7,870	7,260	0,0005
	Disque	3,108	50,160	44,326	0,002
	Poids	2,974	15,840	14,477	0,003
	Javelot	2,587	65,257	58,317	0,010
	Hauteur	2,289	2,090	1,977	0,022
	110m haies	-2,120	14,050	14,606	0,034
	400m	-2,334	48,120	49,616	0,020
	100m	-2,746	10,597	10,998	0,006
Classe 2 ($n = 32$)	Disque	-2,042	43,754	44,326	0,041
	Poids	-2,465	14,309	14,477	0,014
Classe 3 ($n = 3$)	400m	1,961	50,873	49,616	0,050

- **La classe 1** : regroupe les trois athlètes olympiques d'élite : Sebrle, Clay et Karpov. Cette classe est identique à la classe 1 de la CAH et la classe 2 du K-means. L'analyse statistique confirme leur domination sur la majorité des disciplines : la longueur (7,87 m contre 7,26 m), le disque (50,16 m contre 44,33 m), le poids (15,84 m contre 14,48 m), le javelot (5,26 m contre 58,32 m) et la hauteur (2,09 m contre 1,98 m) sont significativement supérieurs à la moyenne. Par contre, les temps réalisées

au 100m (10,60 s), au 400m (48,12 s) et au 110m haies (14,05 s) sont significativement inférieurs à la moyenne, indiquant des qualités en vitesse. Dans le plan ACP, ils occupent à l'extrémité droite de CP1, ce qui confirme leur statut d'athlètes les plus performants et les plus complets du jeu de données.

- **La classe 2** : regroupe la plupart des athlètes, issus des deux compétitions. Son effectif important s'explique par le fait que, dans l'espace réduit, les athlètes se répartissent de façon continue, sans zones de faible densité pour les séparer en plus petits groupes. Contrairement à la CAH et au K-means, qui distinguaient plusieurs classes, DBSCAN regroupe les athlètes dans une seule classe. L'analyse statistique montre seulement deux variables significativement inférieures à la moyenne : le disque (43,75) et le poids (14,31), indiquent des performances collectives plus faible en épreuves de lancer. Dans le plan ACP, ce groupe occupe la zone centrale, cohérente avec un profil moyen et relativement homogène.
- **La classe 3** : regroupe Parkhomenko, Korkizoglou et YURKOV. Dans le plan ACP, ces athlètes se distinguent par des coordonnées élevées sur CP2, axe associé aux épreuves de lancer. La seule variable significative est le 400m ($p = 0,050$), supérieur à la moyenne, indiquant une légère faiblesse en endurance. Leur positionnement dans la partie haute du (CP1,CP2) explique leur identification comme groupe dense distinct par DBSCAN, alors que la CAH les répartissait dans un groupe plus larges.
- **Les points de bruit** : désignent Warners, Drews et Casarsa. Ces trois athlètes occupent des positions atypiques dans le plan (CP1,CP2). Casarsa se situe dans la partie haute gauche, Drews dans la partie inférieure centrale, et Warners dans la partie inférieure droite. Leur profil de performance est donc structuré par des directions spécifiques de l'espace réduit, les éloignant des zones suffisamment dense pour former un *core point*. Ces athlètes ne sont pas des valeurs aberrantes, à titre d'exemple, Warners présente un $\cos^2$ de 0,90 dans le plan (CP1,CP2), indiquant une bonne qualité de représentation mais d'un profil simplement isolé.

4.5.3 Qualité de représentation

La qualité de la partition est évaluée par la silhouette moyenne, calculée en excluant les trois points de bruit pour lesquels le coefficient de silhouette n'est pas défini.

FIGURE 26 – DBSCAN : Qualité de représentation




TABLE 24 – DBSCAN : Silhouette moyenne par classe

Classe	Effectif	Silhouette moyenne
1	3	0.785
2	32	0.189
3	3	0.885
Total	38	0.291

La silhouette moyenne calculée sur les 38 individus hors bruit qui s'élève à 0,291, est supérieure à celles obtenue par la CAH (0,131) et le K-means (0,141).

Les classes 1 et 3 présentent des silhouettes excellentes de 0,785 et 0,885 respectivement, montrant une forte cohésion interne et une séparation marquante avec les autres groupes dans le plan (CP1,CP2). Par contre, la classe 2 présente une silhouette modérée de 0,189, cohérente avec son effectif élevé et la grande diversité des profils qu'elle regroupe.

Finalement, DBSCAN apporte un regard complémentaire aux deux méthodes précédentes : là où la CAH et le K-means imposent une partition exhaustive, DBSCAN identifie les athlètes aux profils

inclassables et confirme que la structure du jeu de données, bien que réelle, ne repose pas sur des densités locales distinctes dans l'espace original des performances.

4.6 Lien entre ACP et les classifications

L'ACP et les méthodes de classification non supervisée sont deux approches complémentaires de l'analyse exploratoire. L'objectif est donc d'examiner dans quelle mesure les groupes identifiés par les méthodes de clustering sont cohérents avec les dimensions données par l'ACP.

Pour se faire, on utilisera le positionnement des classes dans le plan factoriel et le rapport de corrélation η^2 mesurant la proportion de variance de chaque composante expliquée par les classes.

D'après nos sorties R , on a les tableaux suivant :

TABLE 25 – Coordonnées moyennes des classes dans le plan ACP

Méthode	Classe	CP1	CP2	Profil
CAH	Classe 1	4,193	0,748	Extrémité droite de CP1
	Classe 2	0,444	-0,758	Centre-droit de CP1, CP2 négatif
	Classe 3	-0,259	1,347	Centre-gauche de CP1, CP2 élevé
	Classe 4	-2,272	-0,332	Extrémité gauche de CP1
K-means	Classe 1	-1,937	0,604	Gauche de CP1
	Classe 2	4,193	0,748	Extrémité droite de CP1
	Classe 3	0,442	-0,677	Centre-droit de CP1, CP2 négatif
	Classe 4	0,571	-0,108	Centre-droit de CP1, CP2 centre
DBSCAN	Classe 1	4,193	0,748	Extrémité droite de CP1
	Classe 2	-0,282	-0,233	Zone centrale
	Classe 3	-0,871	2,097	CP2 élevé, gauche de CP1
	Bruit (0)	-0,312	-0,362	Positions isolées

TABLE 26 – Rapport de corrélation η^2 entre les classes et les composantes principales

Méthode	η^2 avec CP1	η^2 avec CP2
CAH	0,734	0,470
K-means	0,805	0,176
DBSCAN	0,431	0,239

4.6.1 ACP et CAH

Le rapport de corrélation entre les classes de la CAH et de CP1 s'élève à $\eta^2 = 0,734$, signifiant que les quatre classes expliquent 73,4 % de la variance du premier axe factoriel.

Ce résultat confirme une forte cohérence entre la partition de la CAH et la structure révélée par CP1. Les quatre classes de la CAH s'ordonnent successivement (du groupe le plus performants au moins performant) le long de l'axe.

Le rapport de corrélation avec CP2 est modéré mais significatif avec $\eta^2 = 0,470$. Ce résultat s'explique par la classe 3 de la CAH, dont la coordonnée moyenne sur CP2 est la plus élevée de toutes les classes (1,347).

La CAH a ainsi permis de capturer la dimension CP1, mais également une part importante de la dimension CP2, montrant sa capacité en prendre en compte la structure factorielle des données.

4.6.2 ACP et K-means

Le K-means est mieux aligné avec CP1 que la CAH avec $\eta^2 = 0,805$. Ses classes expliquent 80,5% de la variance du premier axe, ce qui confirme que l'algorithme a construit des groupes cohérents avec la principale dimension de variabilité des données.

En revanche, le rapport de corrélation avec CP2 chute à $\eta^2 = 0,176$. Cela s'explique par le fait que les classes du K-means sont quasiment toutes alignées le long de CP1, avec des coordonnées moyennes sur CP2 proches de zéro (-0,677 et 0,748).

4.6.3 ACP et DBSCAN

Le rapport de corrélation entre les classes du DBSCAN et CP1 atteint $\eta^2 = 0,431$, valeur inférieure à celles obtenues par la CAH et le K-means. Ce résultat s'explique essentiellement par la composition de la classe 2, qui rassemble, à elle seule, 32 individus dans la zone centrale du plan factoriel, avec une moyenne sur CP1 égale à $-0,282$. Ce qui réduit la variance inter-classes sur cet axe. Seule la classe 1 apparaît nettement isolée sur CP1, avec une coordonnée moyenne de $4,193$, traduisant la singularité des trois athlètes d'élite à l'extrémité droite de l'axe.

Le rapport de corrélation avec CP2 atteint $\eta^2 = 0,239$, valeur supérieure celle du K-means et inférieur à celle de la CAH. Ce résultat est porté par la classe 3, dont la coordonnée moyenne sur CP2 s'élève à $2,097$, cette valeur est la plus élevée de toutes les classes issues des différentes méthodes de classification sur cet axe. Grâce à son approche fondée sur la densité, DBSCAN a identifié une classe localisée dans la partie supérieure du plan factoriel, un groupe qui n'était pas détecté avec autant de précision par la CAH ou le K-means.

L'interprétation de ces valeurs de η^2 doit toutefois s'effectuer avec précaution. Contrairement à la CAH et au K-means, dont les classes sont formées dans l'espace à dix dimensions, celles de DBSCAN sont formées directement dans le plan factoriel (CP1,CP2). Donc, son objectif n'est pas de maximiser la variance expliquée par les composantes principales, mais d'identifier des structures de densité dans ce plan réduit. Ce qui explique des valeurs de η^2 plus faibles malgré la cohérence géométrique des groupes observés dans le plan factoriel.

Conclusion

Ce travail avait pour objectif d'explorer les méthodes de classification non supervisée et d'évaluer leur capacité à identifier des structures significatives dans un jeu de données, en s'appuyant sur des critères de validation. À travers cette étude, nous avons montré que la classification non supervisée repose sur des fondements mathématiques indispensables, notamment les mesures de dissimilarité, d'inertie, standardisation et de réduction de dimension par l'ACP.

L'analyse des trois méthodes abordées : classification ascendante hiérarchique, l'algorithme des K-means et DBSCAN, montre que chacune repose sur des principes spécifiques et possède à la fois des avantages et des limites.

La CAH offre une représentation hiérarchique détaillée grâce au dendrogramme, ce qui facilite l'analyse progressive des regroupements. L'algorithme des K-means se distingue par sa simplicité de mise en œuvre et sa rapidité sur les grands jeux de données, bien qu'il nécessite de définir le nombre de classes à l'avance. DBSCAN présente l'avantage d'identifier les points aberrants et de détecter des classes de forme arbitraire, mais son efficacité reste fortement liée aux choix des paramètres MinPts et ϵ .

Les critères de validation étudiés, notamment la méthode de coude et l'indice de silhouette, occupent une place importante dans l'évaluation de la qualité des partitions obtenues. Ces indicateurs permettent d'évaluer objectivement les résultats, et de choisir la partition la plus adaptée.

L'application réalisée sur le jeu de données *Decathlon* a permis de présenter le comportement des différentes méthodes. L'analyse en composantes principales a facilité la visualisation et l'interprétation des données en réduisant leur dimension tout en conservant l'information essentielle. Les trois algorithmes convergent sur une classe d'athlètes d'élites bien identifiée, mais divergent sur certains profils. DBSCAN, en particulier, n'a pas été adapté sur l'espace à dix dimensions et a nécessité une application dans l'espace factoriel de l'ACP.

Cette étude montre qu'il n'existe pas de méthode optimale en classification non supervisée. Le choix d'un algorithme dépend de la nature des données, de leur organisation dans l'espace, de la présence de bruit ainsi que des objectifs de l'analyse. Il est donc nécessaire de bien comprendre les hypothèses, les principes et les limites de chaque méthode afin de choisir la mieux adaptée aux données et d'obtenir des résultats fiables et interprétable.

ANNEXES

A Démonstration du théorème de Huygens

Démonstration.

Par définition, l'inertie totale est :

$$T = \sum_{i=1}^n w_i d^2(x_i, g) \quad (31)$$

où $g = \sum_{i=1}^n w_i x_i$ désigne le centre de gravité global du nuage.

La partition $(C_1, \dots, C_K)$ formant une partition de Ω , tout individu i appartient à exactement une classe C_k . On réécrit la somme globale comme une double somme :

$$T = \sum_{k=1}^K \sum_{i \in C_k} w_i d^2(x_i, g) \quad (32)$$

Pour tout individu $i \in C_k$, on ajoute et soustrait le centre de gravité g_k de la classe C_k :

$$\|x_i - g\|^2 = \|(x_i - g_k) + (g_k - g)\|^2 \quad (33)$$

En développant à l'aide de l'identité $\|a + b\|^2 = \|a\|^2 + 2\langle a, b \rangle + \|b\|^2$ avec $a = x_i - g_k$ et $b = g_k - g$:

$$\|x_i - g\|^2 = \|x_i - g_k\|^2 + 2\langle x_i - g_k, g_k - g \rangle + \|g_k - g\|^2 \quad (34)$$

En substituant cette décomposition dans T et en séparant les trois termes :

$$T = \underbrace{\sum_{k=1}^K \sum_{i \in C_k} w_i \|x_i - g_k\|^2}_{(A)} + 2 \underbrace{\sum_{k=1}^K \sum_{i \in C_k} w_i \langle x_i - g_k, g_k - g \rangle}_{(B)} + \underbrace{\sum_{k=1}^K \sum_{i \in C_k} w_i \|g_k - g\|^2}_{(C)} \quad (35)$$

Le terme (A) est exactement l'inertie intra-classe :

$$(A) = \sum_{k=1}^K \sum_{i \in C_k} w_i \|x_i - g_k\|^2 = W \quad (36)$$

On factorise $g_k - g$, qui ne dépend pas de i :

$$\sum_{i \in C_k} w_i \langle x_i - g_k, g_k - g \rangle = \left\langle \sum_{i \in C_k} w_i (x_i - g_k), g_k - g \right\rangle \quad (37)$$

Or, par définition du centre de gravité g_k :

$$g_k = \frac{1}{\mu_k} \sum_{i \in C_k} w_i x_i \implies \sum_{i \in C_k} w_i x_i = \mu_k g_k \quad (38)$$

Donc :

$$\sum_{i \in C_k} w_i (x_i - g_k) = \sum_{i \in C_k} w_i x_i - g_k \sum_{i \in C_k} w_i = \mu_k g_k - \mu_k g_k = 0 \quad (39)$$

Le produit scalaire est nul, et par conséquent $(B) = 0$.

Dans la somme intérieure, $\|g_k - g\|^2$ ne dépend pas de i , on peut donc le sortir de la somme :

$$\sum_{i \in C_k} w_i \|g_k - g\|^2 = \|g_k - g\|^2 \sum_{i \in C_k} w_i = \mu_k \|g_k - g\|^2 = \mu_k d^2(g_k, g) \quad (40)$$

En sommant sur toutes les classes :

$$(C) = \sum_{k=1}^K \mu_k d^2(g_k, g) = B \quad (41)$$

En substituant, on a :

$$T = W + 0 + B \quad (42)$$

$$\boxed{T = W + B} \quad (43)$$

□

B Scripts R

B.1 Pré-traitement commun

```
if(!require(factoextra)) install.packages("factoextra")
if(!require(FactoMineR)) install.packages("FactoMineR")
if(!require(cluster)) install.packages("cluster")

#Chargement des donnees
load("decath.Rda")

#Resume de decathlon
str(decathlon)
summary(decathlon)

#Selection des variables quantitatives
data_num <- decathlon[, sapply(decathlon, is.numeric)]

#Suppression des variables a double sens
decath_num <- subset(data_num, select = -c(Classement, Points))
decath_num

#Centrage et normalisation
decath_num_scaled <- scale(decath_num)

#Verification de la moyenne ~0 et de l'ecart-type ~1
colMeans(decath_num_scaled)
apply(decath_num_scaled, 2, sd)

#Matrice des correlations des variables
round(cor(decath_num), 2)
```

B.2 Script ACP

```
#Calcul de l'ACP
res.pca <- PCA(decath_num, scale.unit = TRUE, graph = TRUE)

#Valeurs propres et variance
round(res.pca$eig,2)

#Critere de Kaiser
res.pca$eig[, 1] > 1
#Indice des composantes retenues
which(res.pca$eig[, 1] > 1)
#Nombre de composantes retenues
sum(res.pca$eig[, 1] > 1)

#Scree plot
plot(res.pca$eig[, 1],type = "b",xlab = "Composantes_principales",ylab = "
  Valeurs_propres",main = "Scree_plot")
abline(h = 1, lty = 2, col = "red")
#Scree plot avec variance expliquée
fviz_eig(res.pca,addlabels = TRUE,ylim = c(0, 35),main = "Scree_plot_avec_
  variance_expliquee",xlab = "Composantes_principales",ylab = "Pourcentage
  de_variance_expliquee(%)")

#Tableau des contributions des variables a CP1 et CP2
round(res.pca$var$contrib[, 1:2], 2)
#Contribution des variables a CP1
fviz_contrib(res.pca, choice = "var", axes = 1, title = "Contribution_des_
  variables_a_CP1")
#Contribution des variables a CP2
fviz_contrib(res.pca, choice = "var", axes = 2, title = "Contribution_des_
  variables_a_CP2")
#Contribution des variables a CP1 et CP2
fviz_contrib(res.pca,title="Contribution_des_variables_a_CP1_et_CP2",
  choice = "var", axes = c(1,2))

#Tableau des contributions des individus aux CP 1 et 2
round(res.pca$ind$contrib[,1:2],2)
#Contribution a CP1
fviz_contrib(res.pca, choice = "ind", axes = 1, top = 15, title = "
  Contribution_des_athletes_a_CP1")
#Contribution a CP2
fviz_contrib(res.pca, choice = "ind", axes = 2, top = 15, title = "
  Contribution_des_athletes_a_CP2")
#Contribution a CP 1 et 2
fviz_contrib(res.pca, title="Contribution_des_athletes_a_CP1_et_CP2",
  choice = "ind", axes = c(1,2), top = 15)
#Top 15 des individus contribuant le plus a CP1 et CP2
w <- res.pca$eig[1:2,1] / sum(res.pca$eig[1:2,1])
contrib_pond <- as.numeric(res.pca$ind$contrib[,1:2] %*% w)
round(res.pca$ind$contrib[order(contrib_pond, decreasing = TRUE),
  1:2][1:15, ], 2)
```

```

#Qualite de representation des individus sur CP 1 et CP2
round(res.pca$ind$cos2[,1:2],2)
fviz_pca_ind(res.pca,geom = c("point", "text"),col.ind = "cos2",gradient.
  cols = c("lightgray", "blue", "red"),repel = TRUE,title = "Qualite de
  representation (cos2)")
#Qualite de representation moyenne dans le plan ACP
mean(res.pca$ind$cos2[, 1] + res.pca$ind$cos2[, 2])
#Individus les mieux representes
cos2 <- round(res.pca$ind$cos2[, 1:2], 2)
head(cos2[order(cos2[,1] + cos2[,2], decreasing = TRUE), ], 10)

# Construire un data frame avec les 10 variables + Competition
data_pour_pca <- cbind(decath_num, Competition = decathlon$Competition)
#Repartition des athletes
fviz_pca_ind(res.pca, geom.ind = c("point", "text"),habillage = data_pour_
  pca$Competition,palette = "jco",addEllipses = TRUE,legend.title = "
  Competition",repel = TRUE,title = "Repartition des athletes en fonction
  de la competition")

#Correlations des variables avec CP1 et CP2
round(res.pca$var$cor[, 1:2], 2)
#Coordonnees des individus sur CP1 et CP2
round(res.pca$ind$coord[, 1:2], 2)
#Tableau des coordonnees des individus sur les 3 premieres composantes
data_acp <- res.pca$ind$coord[, 1:3]
data_acp

```

B.3 Script CAH

```

#ACP pour la projection des clusters
res.pca <- PCA(decath_num, scale.unit = TRUE, graph = FALSE)

#Classification ascendente hierarchique
classif = agnes(decath_num_scaled,method="ward")
summary(classif)

#Representation du dendrogramme
plot(classif,xlab="Individu",ylab="Hauteur", main="Dendrogramme de
  Decathlon")

#Conversion de la CAH en hclust
classif2 <- as.hclust(classif)

#Decoupage visuel possible
plot(classif2,xlab="Individu",ylab="Hauteur", main="Dendrogramme de
  Decathlon")
rect.hclust(classif2, k = 3, border = "red")
rect.hclust(classif2, k=5,border="blue")

```

```

#Hauteur des fusions
classif2$height

#Saut d inertie
plot(rev(classif2$height), type = "h",xlab = "Nombre_de_classes",ylab = "
    Hauteur_de_fusion",main = "Saut_d_inertie_(CAH)_")

#Methode des silhouette
sil_width1 <- numeric(10) #Stockage des silhouettes moyennes
for(k in 2:10){
    classes1 <- cutree(classif2, k = k) #Decoupe de la cah en k classes
    sil1 <- silhouette(classes1, dist_matrix) #Silhouette de chaque individu
    sil_width1[k] <- mean(sil1[, 3]) #Moyenne de la colonne 3
}
plot(1:10, sil_width1, type = "b",xlab = "Nombre_de_clusters",ylab = "
    Largeur_moyenne_de_silhouette",main = "Methode_des_silhouettes_(CAH)")

#Decoupe en 4 classes
classes2 <- cutree(classif2, k = 4)

#Appartenance des individus aux 4 classes
resultat <- data.frame(Classe = classes2)
resultat

#Visualisation des clusters dans CP1 et CP2
fviz_pca_ind(res.pca,col.ind = as.factor(classes2),addEllipses = TRUE,
    ellipse.type = "convex",legend.title = "Classe",repel = TRUE,title = "
    Clusters_dans_le_plan_ACP")

#Coordonnees moyennes des classes dans CP1
round(tapply(res.pca$ind$coord[, 1], classes2, mean),3)
#Coordonnees moyennes des classes dans CP2
round(tapply(res.pca$ind$coord[, 2], classes2, mean),3)

#Analyse descriptive des classes
aggregate(decath_num, by = list(cluster = classes2), mean)

#Analyse statistique des classes
classes_cah <- cbind(decath_num, Classe = as.factor(classes2))
catdes(classes_cah, num.var = ncol(classes_cah))

#Qualite de representation
sil_cah <- silhouette(classes2, dist_matrix) # Silhouette de chaque
    individu par classes
mean(sil_cah[,3]) #Silhouette moyenne des individus
tapply(sil_cah[, 3], classes2, mean) # Silhouette moyenne des individus par
    classes
fviz_silhouette(sil_cah,main = "Qualite_de_representation_avec_Indice_de_
    Silhouette_(k_=4)" ) +
labs(x = "Individus_(regroupees_par_classe)", y = "Largeur_de_silhouette_(i
    )" ) +
ylim(-0.13, 0.4)

#Effectif des classes
table(classes2)

```

```

#Rapport de corrélation avec CP1
aov1_cah <- aov(res.pca$ind$coord[, 1] ~ as.factor(classes2)) #Analyse de
la variance
ss1_cah <- summary(aov1_cah)[[1]][, "SumSq"]
round(ss1_cah[1] / sum(ss1_cah), 3)
#Rapport de corrélation avec CP2
aov2_cah <- aov(res.pca$ind$coord[, 2] ~ as.factor(classes2))
ss2_cah <- summary(aov2_cah)[[1]][, "SumSq"]
round(ss2_cah[1] / sum(ss2_cah), 3)

#CAH avec d autres criteres d aggregation
#Single linkage
classif_single <- agnes(decath_num_scaled, method = "single")
summary(classif_single)
plot(classif_single, main = "Dendrogramme du lien simple (Single Linkage)",
      xlab = "Individu", ylab = "Hauteur")
rect.hclust(classif_single, k = 4, border = "red")
cl_single <- cutree(as.hclust(classif_single), k = 4)
sil_single <- silhouette(cl_single, dist_matrix)
mean(sil_single[, 3])
#Complete linkage
classif_complete <- agnes(decath_num_scaled, method = "complete")
summary(classif_complete)
plot(classif_complete, main = "Dendrogramme du lien complet (complete
Linkage)", xlab = "Individu", ylab = "Hauteur")
rect.hclust(classif_complete, k = 4, border = "blue")
cl_complete <- cutree(as.hclust(classif_complete), k = 4)
sil_complete <- silhouette(cl_complete, dist_matrix)
mean(sil_complete[, 3])
#Average linkage
classif_average <- agnes(decath_num_scaled, method = "average")
summary(classif_average)
plot(classif_average, main = "Dendrogramme du lien moyen (Average Linkage)",
      xlab = "Individu", ylab = "Hauteur")
rect.hclust(classif_average, k = 4, border = "green")
cl_average <- cutree(as.hclust(classif_average), k = 4)
sil_average <- silhouette(cl_average, dist_matrix)
mean(sil_average[, 3])
#Centroïde
classif_centroid <- hclust(dist_matrix, method = "centroid")
summary(classif_centroid)
plot(classif_centroid, main = "Dendrogramme du centre de gravité (centroid
Linkage)", xlab = "Individu", ylab = "Hauteur")
rect.hclust(classif_centroid, k = 4, border = "purple")
cl_centroid <- cutree(classif_centroid, k = 4)
sil_centroid <- silhouette(cl_centroid, dist_matrix)
mean(sil_centroid[, 3])

```

B.4 Script K-means

```
#ACP pour la projection des clusters
res.pca <- PCA(decath_num, scale.unit = TRUE, graph = FALSE)

#Methode du coude
wss <- numeric(10) # Stockage des valeurs d inertie intra-classe
for(k in 1:10){
  set.seed(123) #Valeur initiale
  km_temp <- kmeans(decath_num_scaled, centers = k,nstart = 25, iter.max =
    100) #Application de K-means
  wss[k] <- km_temp$tot.withinss
}
plot(1:10, wss,type = "b",pch = 16,xlab = "Nombre_de_classes",ylab = "
  Inertie_intra-classe_(WSS)",main = "Methode_du_coude_(K-means)"

#Methode des silhouettes
sil_width2 <- numeric(10)
for(k in 2:10){
  set.seed(123)
  km_temp <- kmeans(decath_num_scaled, centers = k,nstart = 25, iter.max =
    100)
  sil2 <- silhouette(km_temp$cluster, dist_matrix)
  sil_width2[k] <- mean(sil2[, 3])
}
plot(1:10, sil_width2,type = "b",pch = 16,xlab = "Nombre_de_clusters",ylab
  = "Largeur_moyenne_de_silhouette",main = "Methode_des_silhouettes_(K-
  means)")

#Application du K-means avec le nombre de classes retenu
set.seed(123)
km <- kmeans(decath_num_scaled, centers = 4, nstart = 25, iter.max = 100)

#Appartenance des athletes aux 4 classes
km$cluster
#Matrice des coordonnees des 4 classes
km$centers
#Inertie intra-classe totale
km$tot.withinss
#Inertie inter-classes
km$betweenss
#Pourcentage de variance expliquee
km$betweenss / km$totss * 100
```



```

#Visualisation des clusters dans le plan de l'ACP (res.pca)
fviz_pca_ind(res.pca,col.ind = as.factor(km$cluster),addEllipses = TRUE,
  ellipse.type = "convex",legend.title = "Classe",repel = TRUE,title= "
  Clusters_dans_le_plan_ACP")

#Coordonnees moyennes des classes dans CP1
round(tapply(res.pca$ind$coord[, 1], km$cluster, mean),3)

#Coordonnees moyennes des classes dans CP2
round(tapply(res.pca$ind$coord[, 2], km$cluster, mean),3)

#Analyse descriptive des classes
aggregate(decath_num, by = list(cluster = km$cluster), mean)

#Analyse statistique des classes
classes_km <- cbind(decath_num, Classe = as.factor(km$cluster))
catdes(classes_km, num.var = ncol(classes_km))

#Qualite de representation
sil_km <- silhouette(km$cluster, dist_matrix)
mean(sil_km[, 3])
tapply(sil_km[, 3], km$cluster, mean)
fviz_silhouette(sil_km,main = "Qualite_de_representation_avec_Indice_de_
  Silhouette(k=4)") +
labs(x = "Individus_(regroupees_par_classe)",y = "Largeur_de_silhouette_s(i)
  ") +
ylim(-0.12, 0.4)

# Effectif des classes
table(km$cluster)
#Rapport de correlation avec CP1
aov1_km <- aov(res.pca$ind$coord[, 1] ~ as.factor(km$cluster))
ss1_km <- summary(aov1_km)[[1]][, "Sum_Sq"]
round(ss1_km[1] / sum(ss1_km), 3)
#Rapport de correlation avec CP2
aov2_km <- aov(res.pca$ind$coord[, 2] ~ as.factor(km$cluster))
ss2_km <- summary(aov2_km)[[1]][, "Sum_Sq"]
round(ss2_km[1] / sum(ss2_km), 3)

```

B.5 Script DBSCAN

```

if(!require(dbSCAN)) install.packages("dbSCAN")
#ACP pour la projection des clusters
res.pca <- PCA(decath_num, scale.unit = TRUE, graph = FALSE)

# 1. K-distance plot sur les dix variables standardisees (minPts = 4)
kNNdistplot(decath_num_scaled, k = 4)
title("k-distance_plot(k=4)_sur_les_donnees_standardisees")

# 2. Test sur les dix variables standardisees
for (eps_val in c(2.5, 3.0, 3.5, 4.0)) {
  res <- dbSCAN(decath_num_scaled, eps = eps_val, MinPts = 4)
  cat("eps=", eps_val, "|_clusters:_", max(res$cluster), "|_bruit:_", sum(
    res$cluster == 0), "\n")
}
#on a 1 seul cluster dans tous les cas : dbSCAN inadapte en 10D

```

```

# 3. Passage sur les composantes principales
coord<- res.pca$ind$coord[, 1:2]

# K-distance plot sur CP1 et CP2
kNNdistplot(coord, k = 3)
title("k-distance plot (k=3) sur espace (CP1,CP2)")

# Test de parametres sur (CP1,CP2)
for (eps_val in c(1.5, 2.0, 2.5)) {
  res <- dbscan(coord, eps = eps_val, minPts = 3)
  cat("eps=", eps_val, "| minPts=3",
      "| clusters:", max(res$cluster),
      "| bruit:", sum(res$cluster == 0), "\n")
}

# 4. Modele retenu : eps = 1.5, MinPts = 3
res_dbscan <- dbscan(coord, eps = 1.5, MinPts = 3)
res_dbscan

#Composition des clusters
for (k in 0:3) {cat("\n---Cluster", k, ifelse(k == 0, "(bruit)", ""), "----\n")
  print(rownames(decath_num_scaled)[res_dbscan$cluster == k])}

# 5. Visualisation
# Creer un data frame complet avec labels et clusters
df_plot <- data.frame(coord, cluster = as.factor(res_dbscan$cluster), label
  = rownames(coord))

ggplot(df_plot, aes(x = Dim.1, y = Dim.2,
  color = cluster, label = label)) +
  geom_point(size = 2) +
  geom_text(size = 2.5, vjust = -0.6) +
  scale_color_manual(values = c("0" = "black", "1" = "red",
    "2" = "blue", "3" = "green3"),
    labels = c("0" = "Bruit", "1" = "Cluster_1",
    "2" = "Cluster_2", "3" = "Cluster_3")) +
  theme_minimal() +
  labs(title = "DBSCAN: clusters dans CP1/CP2 (eps=1.5, minPts=3)",
    color = "Cluster")

# 6. Profils descriptifs par cluster
clusters_dbscan <- res_dbscan$cluster
clusters_dbscan
# Moyennes par cluster (hors bruit)
aggregate(decath_num[clusters_dbscan != 0, ],
  by = list(Cluster = clusters_dbscan[clusters_dbscan != 0]),
  FUN = mean)
# Caracterisation statistique avec catdes
data_catdes <- data.frame(decath_num, cluster = as.factor(clusters_dbscan))
catdes(data_catdes, num.var = ncol(data_catdes), proba = 0.05)

# 7. Silhouette (hors bruit)
idx <- res_dbscan$cluster != 0
sil <- silhouette(res_dbscan$cluster[idx], dist(coord[idx, ]))
mean(sil[, 3])
summary(sil)

fviz_silhouette(sil) +labs(title = "DBSCAN: silhouette par cluster")

```

```

# 8. Coordonnees moyennes par cluster DBSCAN dans le plan ACP
aggregate(coord, by = list(Cluster = res_dbscan$cluster), FUN = mean)

# 9. Rapport de correlation avec CP1 et CP2
cluster_factor <- as.factor(res_dbscan$cluster)

# Rapport de correlation avec CP1
aov_cp1 <- summary(aov(coord[,1] ~ cluster_factor))[[1]]
eta2_cp1 <- aov_cp1["Sum Sq"][1,] / sum(aov_cp1["Sum Sq"])

# Rapport de correlation avec CP2
aov_cp2 <- summary(aov(coord[,2] ~ cluster_factor))[[1]]
eta2_cp2 <- aov_cp2["Sum Sq"][1,] / sum(aov_cp2["Sum Sq"])

cat("eta2_cp1:", round(eta2_cp1, 3), "\n")
cat("eta2_cp2:", round(eta2_cp2, 3), "\n")

```

B.6 Script Critères d'aggrégation : *USArrests*

Pré-traitement commun

```

library(cluster)

#Chargement des donnees
data(USArrests)

# 6 premieres lignes
head(USArrests)

#Resume de USArrests
str(USArrests)
summary(USArrests)

#Centrage et normalisation
usa_scaled <- scale(USArrests)

#Calcul de la matrice de distances
delta_usa <- dist(usa_scaled, method = "euclidean")

```

CAH : Critère du lien simple

```
#Critere du lien simple
hc_single <- hclust(delta_usa, method = "single")
g_single  <- cutree(hc_single, k = 3)

#Visualisation du dendrogramme
plot(hc_single,
     main = "CAH - Critere du lien simple (single linkage)",
     xlab = "",
     sub  = "",
     ylab = "Hauteur",
     cex  = 0.7,
     hang = -1)
rect.hclust(hc_single, k = 3,
            border = c("blue", "red", "darkgreen"))

#Effectifs par classes
cat("Effectifs du lien simple:", table(g_single), "\n")
```

CAH : Critère du lien complet

```
#Critere du lien complet
hc_complete <- hclust(delta_usa, method = "complete")
g_complete <- cutree(hc_complete, k = 3)

#Visualisation du dendrogramme
plot(hc_complete,
     main = "CAH - Critere du lien complet (complete linkage)",
     xlab = "",
     sub = "",
     ylab = "Hauteur",
     cex = 0.7,
     hang = -1)
rect.hclust(hc_complete, k = 3,
            border = c("blue", "red", "darkgreen"))

#Effectifs par classes
cat("Effectifs du lien complet:", table(g_complete), "\n")
```

CAH : Critère du lien moyen

```
#Critere du lien moyen
hc_average <- hclust(delta_usa, method = "average")
g_average <- cutree(hc_average, k = 3)

#Visualisation du dendrogramme
plot(hc_average,
     main = "CAH - Critere du lien moyen (average linkage)",
     xlab = "",
     sub = "",
     ylab = "Hauteur",
     cex = 0.7,
     hang = -1)
rect.hclust(hc_average, k = 3,
            border = c("blue", "red", "darkgreen"))

#Effectifs par classes
cat("Effectifs du lien moyen:", table(g_average), "\n")
```

CAH : Méthode du centre de gravité

```
#Methode du centre de gravite
hc_centroid <- hclust(delta_usa, method = "centroid")
g_centroid <- cutree(hc_centroid, k = 3)

#Visualisation du dendrogramme
plot(hc_centroid,
     main = "CAH - Methode du centroide (centroid linkage)",
     xlab = "",
     sub = "",
     ylab = "Hauteur",
     cex = 0.7,
     hang = -1)
rect.hclust(hc_centroid, k = 3,
            border = c("blue", "red", "darkgreen"))
```

```

#Effectifs par classes
cat("Effectifs du centroide:", table(g_centroid), "\n")

#Detection des inversions
h <- hc_centroid$height
inv <- which(diff(h) < 0)
if (length(inv) == 0) {
  cat("Centroide: aucune inversion.\n")
} else {
  cat("Nombre d'inversions:", length(inv), "\n")
  for (i in inv) {
    cat("_Etape", i, ": h=", round(h[i], 4), "\n")
    cat("_Etape", i+1, ": h=", round(h[i+1], 4),
        "<-- INVERSION\n")
  }
}

```

CAH : Critère de Ward

```

#Critere de Ward
hc_ward <- hclust(delta_usa, method = "ward.D2")
g_ward <- cutree(hc_ward, k = 3)

#Visualisation du dendrogramme
plot(hc_ward,
     main = "CAH - Methode de Ward",
     xlab = "",
     sub = "",
     ylab = "Hauteur",
     cex = 0.7,
     hang = -1)
rect.hclust(hc_ward, k = 3,
            border = c("blue", "red", "darkgreen"))

#Effectifs par classes
cat("Effectifs de Ward:", table(g_ward), "\n")

```

Synthèse des résultats

```

#Comparaison des methodes
tableau <- data.frame(
  Etat = rownames(USArrests),
  Single = g_single,
  Complete = g_complete,
  Average = g_average,
  Centroide = g_centroid,
  Ward = g_ward
)
print(tableau)

```

Bibliographie

Références

- [1] Brian S. Everitt, Sabine Landau, Morven Leese, Daniel Stahl, *Cluster Analysis*, 5th Edition, Wiley, 2011.
- [2] Jean-Pierre Nakache et Josiane Confais, *Méthodes de classification*, Éditions Technip, 2004.
- [3] Sylviane Wey, *Classification Ascendante Hiérarchique (Chapitre 5)*, Polycopié de cours de Master 1, Université Le Havre Normandie, 2025.
- [4] Jean-Marie Monnez, *Méthodes de classification non supervisée*, Cours d'analyse des données et apprentissage, Université de Lorraine, 2021.
- [5] Marie Chavent, *Classification de données quantitatives*, Cours, Université de Bordeaux, 2013.
https://marie-chavent.perso.math.cnrs.fr/wp-content/uploads/2013/10/cours_classif_quantif.pdf
- [6] Valérie Monbet, *Clustering et Classification Ascendante Hiérarchique (CAH) - Introduction*, Cours, Université de Rennes 1.
https://perso.univ-rennes1.fr/valerie.monbet/ISD/clustering_intro_CAH.pdf
- [7] Christine Keribin, *Apprentissage statistique supervisé et non supervisé*, Cours, Université Paris-Saclay, 2014.
<https://www.imo.universite-paris-saclay.fr/~christine.keribin/STA203/ENSTA-STA203-Poly-2024.pdf>
- [8] Wikistat, *Classification non supervisée*, Université de Toulouse.
<http://wikistat.fr/pdf/st-m-explo-classif.pdf>
- [9] CNAM, *Méthodes de classification*, Support de cours, 2014.
https://maths.cnam.fr/IMG/pdf/METHODES_DE_CLASSIFICATION-2014_cle4ad38b.pdf
- [10] DataCamp, *Normalization vs Standardization : Key Differences Explained*, Tutorial en ligne.
<https://www.datacamp.com/fr/tutorial/normalization-vs-standardization>
- [11] Marie Chavent, *Analyse en composantes principales*, Cours, Université de Bordeaux.
https://marie-chavent.perso.math.cnrs.fr/wp-content/uploads/2013/10/ACP_L3.pdf
- [12] Wilson Toussile, *Analyse en Composantes Principales (ACP) : Un Guide Complet*.
<https://toussile.quarto.pub/data-science/posts/machine-learning/reduction-dimentionalite/02-acp.html>
- [13] Ricco Rakotomalala *Analyse en Composantes Principales (ACP)*, Cours, Université Lumières Lyon 2.
<https://eric.univ-lyon2.fr/ricco/cours/slides/ACP.pdf>
- [14] CNAM, *Reconnaissance des formes et méthodes neuronales (RCP208) : Classification automatique par densité (DBSCAN)*.
<https://cedric.cnam.fr/vertigo/Cours/ml/docs/3coursDBSCAN.pdf>
- [15] DataCamp, *A Guide to the DBSCAN Clustering Algorithm*, Tutoriel en ligne.
<https://www.datacamp.com/fr/tutorial/dbscan-clustering-algorithm>
- [16] Ricco Rakotomalala, *Mesures de qualité des partitions en classification automatique*, Université Lyon 2.
https://eric.univ-lyon2.fr/ricco/cours/slides/classif_mesures.pdf
- [17] TÉLUQ, *INF1421 - Module 6 : Regroupement (Clustering)*, 2019.
<https://inf1421.teluq.ca/files/2016/09/INF1421-Module6-Regroupement-Jan2019.pdf>